

Estado del arte en generación y detección de contenido sintético. Limitaciones y oportunidades

Miguel Hernández Boza
BBVA Next Technologies
Av. Manoteras 44. Planta 5. 28050 Madrid
<https://orcid.org/0000-0001-8610-6225>

José Ignacio Escribano Pablos
BBVA Next Technologies
Av. Manoteras 44. Planta 5. 28050 Madrid
<https://orcid.org/0000-0002-0079-642X>

Resumen—Los avances en nuevas tecnologías, sobre todo las relacionadas con inteligencia artificial y el auge del *deep learning*, han puesto en tela de juicio los mecanismos tradicionales para determinar si una información es legítima o no. Herramientas como *StyleGAN2*, *GROVER* o *Deepfake* son buenos ejemplos de cómo es posible generar información manipulada de alta calidad. En este artículo, se detallan las técnicas, algoritmos y herramientas que permiten generar y detectar contenido falso, profundizando en cada área (audio, texto, imagen y vídeo) haciendo énfasis en las limitaciones que existen en su uso para generar identidades falsas para cometer cualquier tipo de fraude.

Index Terms—Contenido Sintético, Deep Learning, Inteligencia Artificial, redes GAN, Seguridad Defensiva, Seguridad Ofensiva, Fake News.

Tipo de contribución: Investigación original

I. INTRODUCCIÓN

Cada vez más, se están desarrollando técnicas de aprendizaje automático (*machine learning*, en inglés) relacionadas con la seguridad de la información, evolucionando y aplicándose en diversos ámbitos. Desde la generación y detección de archivos maliciosos basados en mutaciones automáticas, reconocimiento masivo de personas a través de visión computacional hasta el tema que nos ocupa en este artículo con la generación de perfiles sintéticos que permitan a un atacante engañar fácilmente a usuarios o máquinas. Debido a esto, es necesario analizar las medidas defensivas a las que podemos acudir para poder protegerse frente a este nuevo vector de ataque.

I-A. Machine Learning y ciberseguridad

En los últimos años, el *machine learning* [1], y en particular, el *deep learning* [2] se han convertido en potentes herramientas con las que automatizar una gran cantidad de procesos, mejorando en muchos casos la detección de patrones en grandes cantidades de datos. Se ha aplicado con éxito en multitud de ámbitos como medicina o astronomía. Un área donde el *machine learning* ha cobrado una notable relevancia es la seguridad de la información, ya que es posible aplicarlo en múltiples escenarios como pueden ser la detección de anomalías en tráfico de red [3–5], la clasificación de malware automática [6–8], la detección de vulnerabilidades [9–11] o la estenografía [12–14] entre otros.

Además de estos casos, ha aparecido una nueva rama de investigación relacionada con la generación de datos a partir de estos algoritmos de *deep learning*. Estos nuevos algoritmos están basados en redes GAN [15], dos redes neuronales contrapuestas donde aparece un generador y un detector que aprenden el uno del otro hasta llegar a un

equilibrio. Este nuevo paradigma también ha sido aplicado en ciberseguridad [16] con gran éxito como por ejemplo en la destrucción de contenido oculto con estenografía [17]. Un análisis detallado de las áreas de aplicación en ciberseguridad se pueden encontrar en [18–22].

Organización. La Sección II contiene algunas de las manipulaciones clásicas de información que se han dado a lo largo de la historia y la Sección III todo lo relacionado con contenido sintético y las amenazas en ciberseguridad. Las Secciones IV y V se centran en la generación y detección de contenido en audio, texto, imagen y vídeo, respectivamente, poniendo énfasis en las herramientas *open source*. La Sección VI contiene las próximas tendencias y amenazas que pueden tener lugar en el futuro. Por último, la Sección VII contiene las conclusiones de la investigación realizada.

II. MANIPULACIONES CLÁSICAS

Siempre ha existido la modificación o manipulación de información [23], [24], pero con el paso del tiempo ha ido evolucionando. Comenzó con casos muy rudimentarios, manipulaciones caseras o muy burdas pero efectivas que pretendían causar un gran impacto social (manipulaciones en carteles de manifestaciones) o provocar una reacción en la gente, como el vandalismo. Tradicionalmente la manipulación se ha dado en imágenes y se tiene constancia que desde 1860 se han empleado técnicas en manipulación (*Fig. 1*) que llegan hasta nuestros días. Otras manipulaciones clásicas de imágenes se pueden ver en [25].




Figura 1: Foto manipulada de Abraham Lincoln de alrededor de 1860. A la izquierda se muestra la imagen manipulada y a la derecha la imagen original. Fuente: [25].

Otros ejemplos más recientes vienen dados por el uso de herramientas como Photoshop, una herramienta de retoque y

edición de fotografías, que desde versiones iniciales permitía la manipulación de imágenes con una gran calidad de salida.

A raíz del crecimiento exponencial del *deep learning* y las redes GAN, la generación de contenidos multimedia de forma automática y masiva se ha vuelto una realidad. En las Figs. 2 y 4 se puede ver algunas de las técnicas más sofisticadas en cuanto a generación y detección, respectivamente.

III. CONTENIDO SINTÉTICO

Contenido sintético es un término general para la producción, manipulación y modificación artificial de datos y por medios automatizados, especialmente mediante el uso de algoritmos de inteligencia artificial, por ejemplo, con el fin de engañar a las personas [26]. En este artículo, este contenido sintético estará centrado en el contenido multimedia que trata de ser lo más verídico posible tratando de engañar a personas o máquinas.

El contenido de los medios sintéticos ha crecido rápidamente desde la creación de las redes GAN, principalmente mediante el aumento de las *fake news* [27], así como, a la generación de caras hiperrealistas, la síntesis de voz y los *deepfakes*.

III-A. Amenazas en ciberseguridad

El aumento de la generación de contenido sintético supone una serie de amenazas en ciberseguridad. En el caso de audio, las técnicas actuales permiten crear voces humanas que puedan aparentar ser de una persona real (clonada)¹ o de una persona que no exista (basada en una fuente de datos)². Esto podría permitir la suplantación de personas. En imágenes, aparece la capacidad de crear rostros realistas de personas que no existen³, lo que implica poder crear identidades falsas. En el caso del texto, da la posibilidad de crear textos coherentes falsos⁴ con el fin de mejorar la creación de *fake news*, y por último en vídeo, es posible insertar caras en cuerpos que no se corresponden con la persona original⁵.

Los medios sintéticos incluyen el potencial de crear noticias falsas, propagar la desinformación, aumentar la desconfianza en la realidad y automatizar de forma masiva de los trabajos creativos y periodísticos.

IV. GENERACIÓN DE CONTENIDO SINTÉTICO

En esta sección se desgranarán los métodos y modelos que se utilizan actualmente para realizar contenido sintético, centrándose en el contenido multimedia con el objetivo de ser lo más similar posible al contenido real. Para ello, las herramientas hacen uso de las técnicas de *deep learning* que se han mencionado en la Sección I-A. En la Fig. 2 se puede ver la evolución de las técnicas en la generación de contenido.

IV-A. Audio

En los últimos años, distintas empresas como Lyrebird⁶ o Resemble.ai⁷ han aparecido en el panorama con el objetivo

de clonar voz usando inteligencia artificial. Lyrebird prometía clonar una voz empleando sólo 30 frases predefinidas de antemano. Con estas frases, la inteligencia artificial era capaz de entrenar los audios con las frases grabadas y obtener un modelo de la voz. La limitación de este sistema es que está pensado para clonar voces en inglés. De igual forma, Resemble.ai es una plataforma similar a Lyrebird cuyo objetivo es clonar voces. En este caso, requiere 50 frases prefijadas (en inglés) para clonar una voz. La novedad que presenta esta plataforma es que dispone de distintas voces preentrenadas, incluyendo distintos acentos y voces masculinas y femeninas. En particular, incluye voces en español tanto en español de España como de Sudamérica.

Dejando a un lado las dos herramientas anteriores, Real Time Voice Cloning [28] es la herramienta *open source* más potente de clonado de voz, cuyo código está disponible en GitHub [29]. Está compuesto de cuatro partes: SV2TTS [30], WaveRNN [31] como *vocoder*, Tacotron 2 [32] como sintetizador y GE2E [33] como *encoder*. El objetivo de la herramienta es clonar una voz usando sólo 5 segundos de audio. Después de realizar distintos experimentos con esta herramienta siguiendo la configuración descrita en su manual, no hemos conseguido obtener una voz realista usando sólo 5 segundos. Esta herramienta sólo requiere un audio de la voz que se requiera clonar y el texto que dirá la voz clonada. Los resultados más prometedores se han obtenido al emplear unos 10 minutos de audio. A modo de ejemplo, usando 10 minutos de un discurso de Donald Trump⁸ se pueden obtener resultados realistas, aunque lejos de ser perfectos, ya que es posible escuchar cierto tono robótico. De hecho, si se emplean textos con palabras complejas, como pueden ser textos de Shakespeare⁹, se pueden ver las limitaciones del modelo entrenado: no es capaz de generalizar palabras que no ha visto con anterioridad. Esto pone en entredicho que esta herramienta se pueda emplear para clonar todas las voces y convertir a voz cualquier texto. Esta limitación se suma a la comentada previamente sobre el idioma: solamente genera voces en inglés. Para generar voces en otros idiomas, es necesario disponer de un conjunto de datos de alrededor de 300 horas en el idioma deseado de más de 100 personas distintas¹⁰. Los proyectos anteriormente mencionados requieren de datos que son costosos de obtener, sin embargo, los proyectos de Common Voice de Mozilla¹¹ o M-AILABS¹² proporcionan una serie de datos interesantes. El primero dispone de audios en muchos idiomas, incluyendo el español, aunque la calidad no es demasiado buena, debido a que los micrófonos con los que ha sido grabados no tienen la suficiente calidad. El segundo, M-AILABS, dispone también de audio en distintos idiomas; este conjunto de datos está pensado para ser empleado en algoritmos de inteligencia artificial, aunque, no todos los audios disponibles de este conjunto de datos disponen de las horas suficientes para hacer funcionar Real Time Voice Cloning.

Con todas estas aplicaciones queda claro que es posible llegar a clonar una voz de manera sintética con un alto grado

¹<https://www.pandasecurity.com/mediacenter/news/deepfake-voice-fraud/>

²<https://youtu.be/s0UJCb5ZjJ0>

³<https://www.wired.com/story/facebook-removes-accounts-ai-generated-photos>

⁴<https://talktotransformer.com/>

⁵<https://youtu.be/GTh2tRAE2w4>

⁶Ahora forma parte de Descript, una empresa de transcripción de audio a texto de forma automática. <https://www.descript.com/lyrebird-ai>

⁷<https://www.resemble.ai>

⁸<https://youtu.be/KWcmZ8hozvU>

⁹<https://tinyurl.com/zxg8qle>

¹⁰<https://git.io/JvEbj>

¹¹<https://voice.mozilla.org>

¹²<https://www.caito.de/2019/01/the-m-ailabs-speech-dataset>




Figura 2: Principales hitos en la generación de contenido sintético.

de fiabilidad si se tienen los suficientes datos disponibles. Si se quisiera realizar un ataque real, es posible realizar inyecciones de audio clonado para suplantar a otra persona [34].

IV-B. Texto

Siempre ha existido un gran interés por la redacción de textos automática, al igual que un gran conocimiento sobre cómo puede tratar la máquina con los textos. Este tema sería una extensión del conocido como procesamiento natural del lenguaje, que permite un análisis de un texto sintético y semánticamente.

Cuando hablamos de generar un texto sintético empleando *deep learning*, los sistemas actuales están basados en la premisa de predecir la siguiente palabra dado un mensaje o contenido inicial, ya que por sí solos no son capaces de generarlo. A partir de este concepto, diversos investigadores comenzaron a buscar fuentes de datos que fueran lo suficiente ricos en contenido para que los modelos pudieran aprender. OpenAI liberó el modelo GPT [35] y tras unos años de controversia sobre los usos éticos del generador también liberó su evolución llamada GPT-2 [36], un modelo compuesto de 1 500 millones de parámetros. A raíz de su publicación, se han desarrollado distintas aplicaciones *online* donde probar este modelo. Un ejemplo de esto es *Talk to Transformer*¹³. La versión más reciente es GPT-3 [37], que permite interpretar textos. Este modelo no es *open source* y se requiere de licencia para usarse.

Este no es el único modelo, existen muchos otros como CTRL [38] o GROVER [39] que mantienen esta premisa, en el caso de GROVER permite tanto la generación como detección de texto.

Usando GPT-2 o GROVER es posible ver las limitaciones en cuanto al idioma que tienen estos sistemas, ya que al ser entrenados en inglés están forzados a utilizar ese lenguaje para funcionar correctamente. Aún así, existen casos de éxito a la hora de simular un comportamiento humano. Por ejemplo, esto sucede en redes sociales como Twitter que además tienen la limitación de cantidad de caracteres: muchos *bots* envían mensajes para evitar ser detectados por los sistemas anti-automatización. En STIC CCN-CERT se publicó¹⁴ que algunos simpatizantes con el Brexit eran *bots* controlados por los ponentes.

Por lo tanto, siempre que el idioma no sea un impedimento, empiezan a aparecer usos maliciosos que ya preveía OpenAI¹⁵ antes de liberar su sistema y es necesario combatirlo de manera efectiva. En la sección V-A de detección de audio profundizaremos en ello.

IV-C. Imagen

StyleGAN [40] es la herramienta estado del arte en generación de imágenes de caras hiperrealistas, desarrollada por NVIDIA Labs. Tanto el código como los datos de entrenamiento han sido liberados en GitHub [41], [42], junto con los modelos preentrenados disponibles en Google Drive¹⁶. StyleGAN emplea una modificación de la red GAN [15] como arquitectura y conseguir resultados hiperrealistas. Algunas de las imágenes generadas con StyleGAN se puede ver en la Fig. 3. Se pueden observar algunas de las limitaciones de este sistema: una oreja sobresale por encima del pelo, los pendientes son de distinto tipo colgando en el aire y los dientes no están alineados con respecto al centro de la cara (los dientes se muestran como si la cara estuviese siempre de frente). Para solucionar estos problemas, a finales de 2019, se liberó una nueva versión, llamada StyleGAN2 [43]. En esta segunda versión se han empleado los mismos datos de entrenamiento que en la primera versión, pero la arquitectura de la red GAN se ha modificado para que corrija los problemas descritos anteriormente. Como en la versión previa, todo el código y modelos preentrenados han sido publicados [44]. Además, esta nueva versión introduce el concepto de *proyección* que, dada una imagen objetivo, se itera para obtener la imagen más similar que se podría obtener con StyleGAN2. Si la imagen ha sido generada por este sistema, la imagen de la proyección converge a una imagen muy similar de la imagen objetivo. Sin embargo, si la imagen objetivo es una imagen real las proyecciones convergerán a una imagen muy distinta a la objetivo (ver Fig. 5 para un ejemplo). StyleGAN2 es el modelo empleado en la página más famosa de generación de caras falsas: <https://www.thispersondoesnotexist.com>. La versión más reciente es StyleGAN-ADA [45], que necesita menos datos de entrenamiento obteniendo resultados similares a StyleGAN2.

Los datos de entrenamiento de StyleGAN también han sido publicados en GitHub [42] bajo el nombre de FFHQ. Los datos constan de 70 000 imágenes de caras de tamaño 1024x1024 extraídas de Flickr¹⁷ con licencia de libre uso y redistribución fijada por los autores de las fotos. Este conjunto de datos tiene una mayor variabilidad en cuanto a edad, grupos étnicos, accesorios (gafas, gafas de sol, gorros, etc.) y fondos de imágenes que conjuntos de datos previos como CELEBA-HQ [46], aunque el conjunto de datos hereda todos los sesgos (*bias*) presentes en Flickr.

IV-D. Vídeo

Los avances en la digitalización de los rostros humanos se han convertido en la base de las modernas herramientas de edición de imágenes faciales. Las herramientas de edición de

¹³<https://talktotransformer.com>

¹⁴<https://youtu.be/wzctZgha1yw>

¹⁵<https://www.theverge.com/2019/11/7/20953040/openai-text-generation-ai-gpt-2-full-model-release-1-5b-parameters>

¹⁶<https://tinyurl.com/t5ys8dq>

¹⁷<https://www.flickr.com>




Figura 3: Algunas de las limitaciones en la generación de StyleGAN. Imágenes generadas usando el código oficial disponible en GitHub [41].

vídeo pueden dividirse en dos categorías principales: modificación de la identidad, con herramientas como FaceSwap [47], y modificación de la expresión, con Face2Face [48]. Pero estas no son las únicas herramientas que existen. En la Tabla I se enumeran las más reconocidas cuyo código está disponible. Estas herramientas están diseñadas para generar *deepfakes*, vídeos modificados en los que una cara se ha introducido en un vídeo objetivo. El estado del arte sobre la generación de *deepfakes* se puede encontrar en [49].

Tabla I: Algunas herramientas *open source* para crear *deepfakes*.

Herramienta	URL
Deepfakes	https://github.com/deepfakes/faceswap
Faceswap-GAN	https://github.com/shaoanlu/faceswap-GAN
DFaker	https://github.com/dfaker/df
DeepFaceLab	https://github.com/iperov/DeepFaceLab

En nuestros experimentos, hemos empleado la herramienta Deepfakes [50] para crear *deepfakes*, aunque las demás herramientas de la Tabla I tienen un funcionamiento similar. Esta herramienta se encarga de generar *deepfakes* en tres fases: extraer caras, entrenar el modelo e insertar las caras. La extracción de caras se puede realizar a través de distintos extractores disponibles en la herramienta. El entrenamiento del modelo se realiza a partir de las caras extraídas en el paso anterior, produciendo un modelo que es capaz de transformar una cara en otra. El tercer y último paso, a partir de un vídeo objetivo, transforma la caras aplicando del modelo entrenado previamente, fotograma a fotograma. Para obtener resultados aceptables con esta herramienta es necesario disponer de una GPU. En nuestro caso, empleamos una NVIDIA GTX 1080 con 8GB de RAM. Además, es imprescindible contar con una gran cantidad de vídeos de los que extraer las caras que cuenten con distintos ángulos e iluminaciones. En la medida de lo posible, estos vídeos deben tener la mejor resolución posible. En nuestro caso, empleamos vídeos en calidad 1920x1080 (*Full HD*). A la hora de extraer las caras de los vídeos, se debe comprobar manualmente que las caras extraídas se corresponden con las caras que queremos extraer y eliminar falsos positivos para evitar que el modelo entrenado sea de la mejor calidad posible. En nuestras pruebas empleamos entre 10 y 40 minutos de vídeo, quedando entre 3000 y 15000 caras después de eliminar los falsos positivos del detector de caras. El entrenamiento del modelo, en nuestras pruebas con el *hardware* descrito anteriormente, tardó entre 1.5 y 2 días, no produciendo mejores resultados

dejando continuar el entrenamiento de forma indefinida¹⁸. Los vídeos¹⁹ tienen ciertas limitaciones:

- El detector de caras sólo detecta una cara: si se aplica a un fotograma con más de una cara sólo detecta la que sea más grande o la que encuentre primero.
- Los fotogramas con caras lejanas o con determinadas posiciones de la cara tampoco son detectadas.
- Si se detecta una cara de persona con la que ha sido entrenada se producen resultados no esperados que son fácilmente detectados.
- Si se aplica a caras que tengan gafas, barbas o similares se producen resultados extraños, siendo el modelo incapaz de generalizar de forma correcta.

V. DETECCIÓN DE CONTENIDO SINTÉTICO

El fuerte impacto que tienen los *deepfakes* en la sociedad, hizo que DeepTraceLab se preguntara si la generación de contenido sintético es un problema real. Las conclusiones fueron claras, los *deepfakes* estaban centrados en el contenido adulto y no en política [51]. Por otro lado, Danielle Citron en una charla en TED²⁰ explica qué poder hacer para verificar una información real, ya que podemos empezar a dudar de ella también. Con todo esto, es necesario poner énfasis en la búsqueda de soluciones para protegernos, ya que la exposición a este tipo de material es inevitable. En la siguiente sección se describen herramientas o modelos que permiten la detección del contenido sintético.

V-A. Audio

La voz nos identifica y en muchos casos nos autentica en un sistema, por lo que es necesario protegerla y seguramente ni nos damos cuenta de la exposición que le damos cada día. En la sección de generación se ha demostrado que con los suficientes datos es posible replicar una voz con gran precisión, difícil de detectar de manera manual. Por lo tanto, debido al posible uso fraudulento de estas nuevas técnicas, se ha vuelto urgente encontrar métodos de detección de voces clonadas.

En el evento sobre procesamiento de voz, Interspeech 2019²¹, se trató el problema de detectar voces sintéticas, después de la generación que tuvo lugar en años anteriores.

¹⁸Deepfakes fija el número de iteraciones a 1 millón, aunque este parámetro es personalizable por el usuario.

¹⁹Deepfakes no genera el vídeo propiamente dicho sino que transforma las caras fotograma a fotograma, aunque proporciona herramientas para unir todos los fotogramas y formar el vídeo.

²⁰<https://www.daniellecitron.com/ted-talk>

²¹<https://www.interspeech2019.org>




Figura 4: Principales hitos en la detección de contenido sintético.

Dentro de este evento se desarrolló el reto ASVspoof 2019 donde diversas universidades trataron de crear un modelo o herramienta que, dados unos datos etiquetados como reales o falsos, fuera capaz de identificar cómo de falsa era una voz introducida [52]. Una de las soluciones, llamada *Fake Audio Detector* publicó el código [53] en GitHub. En el repositorio se proporciona el código y el modelo preentrenado sobre el que realizar pruebas y verificar si una voz es real o no.

Esta herramienta se probó en distintos experimentos con diversos tipos de audio: muestras de Real Time Voice Cloning, Resemble.ai y Lyrebird. Los resultados obtenidos fueron inconsistentes, puesto que al introducir tanto audios falsos como reales, la probabilidad que devolvía la herramienta de ser reales en ambos casos era muy baja. Por lo que se puede decir que no son unos resultados lo suficientemente robustos como para valorar esta solución como algo fiable.

V-B. Texto

La detección de texto se está centrando en la detección de *fake news*. Los investigadores están proponiendo en la actualidad distintas técnicas para detectar este tipo de noticias manipuladas. Los grafos [54], [55] y *Capsule Neural Networks* [56] son alguna de las técnicas más novedosas para detectar este tipo de noticias. En paralelo, también se están centrando los esfuerzos en crear sistemas que recopilen, analicen y detecten *fake news* de forma automática. Ejemplos de esto son *Kauwa-Kaate Fake News Detection System* [57], *FakeNewsTracker* [58] o *DEFEND* [59] cuyo objetivo es detectar y explicar por qué las noticias detectadas son falsas.

GROVER [39] es una de las herramientas más conocidas en cuanto a la detección de *fake news*²². Los creadores de GROVER han liberado los modelos preentrenados y el código en GitHub [60] y se puede probar este sistema a través de su demo online²³. Este sistema se ha creado con el objetivo de que los atacantes que generan *fake news* para difundir propaganda o hacer *clickbait* sean detectados fácilmente. Emplea la misma arquitectura que GPT-2 [36], aunque para entrenarlo se ha empleado un conjunto de datos llamado REALNEWS²⁴. Este conjunto de datos ha sido formado por noticias procedentes de *Common Crawl*²⁵. Las noticias extraídas para el entrenamiento tienen fechas comprendidas entre diciembre de 2016 y abril de 2019 para el entrenamiento y noticias desde abril de 2019 para la evaluación del modelo. Este conjunto de datos tiene un tamaño de 120 GB sin comprimir.

²²GROVER también permite generación de *fake news*, aunque sólo nos centraremos en la detección.

²³<https://grover.allenai.org>

²⁴<https://github.com/rowanz/grover/tree/master/realnews>

²⁵<https://commoncrawl.org>

En cuanto a detectores de propósito general, GLTR [61] es uno de los más empleados. Está disponible en GitHub [62] y se puede probar de forma online²⁶. Permite detectar textos generados con GPT-2 [36] y la detección se basa en cómo funciona este modelo, es decir, prediciendo la siguiente palabra. Así pues, GLTR va iterando por el texto y va comprobando si la siguiente palabra que aparece en el texto que queremos comprobar si es real o falso, se comprueba si aparece en las *k* primeras palabras de GPT-2. De esta forma se puede dar una estimación de cómo de sintético es un texto dado.

V-C. Imagen

Existe un gran número de trabajos que tratan de verificar la integridad de imágenes [63]. Por otro lado, también se está trabajando en la detección de imágenes generadas con herramientas tradicionales como Photoshop. Este es el caso de FAL [64], que permite detectar si una foto ha sido modificada con Photoshop a través de *Face-Aware Liquify*²⁷ disponible en Photoshop. *Face-Aware Liquify* permite cambiar expresiones faciales de una cara en unos pocos *clicks*.

En cuanto a detección de imágenes generadas artificialmente, se han propuesto numerosas alternativas. GAN Fingerprints [65] permite la detección de distintas redes GAN por el ruido introducido en la generación de la imagen. Las redes GAN que detecta son: ProGAN [46], SNGAN [66], CramerGAN [67] y MMDGAN [68]. Otra aproximación es *FakeSpotter* [69], que se basa en monitorizar el comportamiento de las neuronas de un modelo para detectar las imágenes generadas usando un clasificador binario, siendo empleado con éxito en distintos métodos de generación: ProGAN [46], StyleGAN2 [43], STGAN [70].

La detección de StyleGAN [40] y StyleGAN2 [43] se puede realizar a través de las proyecciones presentadas en StyleGAN2 y descritas en la Sección IV-C. Si empleamos como imagen objetivo (la imagen que queremos comprobar si es sintética o no) una imagen generada con cualquiera de las versiones de StyleGAN, las proyecciones convergerán a una imagen muy similar al objetivo. Sin embargo, empleando una imagen no sintética, las proyecciones no convergen al objetivo sino a una imagen que se diferencia significativamente del objetivo. Un ejemplo de detección de imágenes con este método se puede ver en la Fig. 5.

V-D. Vídeo

Detectar los *deepfakes* [71] se ha vuelto una necesidad debido al uso malicioso que pueden tener en áreas como la

²⁶<http://gltr.io/dist/index.html>

²⁷<https://helpx.adobe.com/es/photoshop/how-to/face-aware-liquify.html>



(a) Imagen generada por StyleGAN



(b) Imagen generada por StyleGAN2



(c) Imagen no sintética

Figura 5: Proyecciones de StyleGAN2 usando una imagen generada por StyleGAN (a), por StyleGAN2 (b) y una no sintética (c). A la izquierda se muestra la imagen objetivo y a la derecha el resultado de aplicar las proyecciones después de 1000 iteraciones. Para generar las proyecciones se ha utilizado el código oficial de StyleGAN2 publicado en GitHub [44].

política. Han aparecido ya trabajos que permiten reconocer incoherencias en el parpadeo [65], sincronización del movimiento de los labios [72], [73] u otros [72], [74], [75]. Es necesario disponer de sistemas automáticos que no necesiten de un procesamiento muy grande para poder verificar un vídeo. Es por ello que han aparecido retos como DFDC [76] y bases de datos como CELEB-DF [77] para tratar de generar modelos de detección de *deepfakes*.

FaceForensics++ [78] es la herramienta, de código libre [79], más avanzada en cuanto a la detección de *deepfakes*. Esta herramienta permite detectar si un vídeo ha sido manipulado. La forma de funcionar es relativamente sencilla: el vídeo es dividido en fotogramas y por cada uno de ellos, se calcula la probabilidad de que el fotograma sea falso usando un modelo preentrenado. Este es un modelo de *deep learning* entrenado con vídeos extraídos de YouTube y estos mismos vídeos generados como *deepfakes* usando cuatro métodos de generación: DeepFakes [50], Face2Face [48], FaceSwap [80] y NeuralTextures [81].

Después de realizar distintos experimentos con FaceForensics++ (ver Fig. 6), es capaz de detectar *deepfakes* aunque tiene ciertas limitaciones que enumeramos a continuación:

- Sólo es capaz de detectar *deepfakes* que hayan sido creados con uno de los métodos con los que ha sido

entrenado.

- En caso de que un mismo fotograma aparezca más de una cara, FaceForensics++ sólo aplica la detección a la cara más grande que detecte. Esto hace que se pueda evadir la detección si se inserta el *deepfake* en alguna de las caras más alejadas, aunque esta limitación sólo aplica a vídeos en los que aparece más de una cara.
- Falsos positivos. Normalmente estos positivos vienen dados por reconocimiento erróneo de caras, que en este caso se heredan de la librería de reconocimiento facial dlib [82] que emplea FaceForensics++ de forma interna.
- Díficil de instalar. La falta de información en el repositorio [79] hace que sea difícil de instalar, teniendo que cambiar rutas del código de los modelos preentrenados que se encuentran con rutas absolutas y no relativas, lo que hace que esta herramienta no sea apta para personas no técnicas.

FaceForensics++ puede ser evadido usando técnicas de *adversarial machine learning* [83], usando ejemplos adversarios (pequeñas perturbaciones añadidas a ejemplos legítimos imperceptibles para el ojo humano que hacen clasificar de forma incorrecta al modelo). Este es el ejemplo de *Adversarial Deepfakes* [84], que propone modificar de forma imperceptible usando pequeñas perturbaciones en los *deepfakes* creados con los métodos de generación vistos en la Sección IV-D, siendo efectivos tanto en caja negra (método de detección desconocido) como en caja blanca (método de detección conocido). Además, los autores demuestran que el método propuesto es robusto frente a *códecs* de compresión de audio y vídeo [84].

VI. FUTURO

A partir de todo lo visto en este artículo, queda claro que queda mucho trabajo por hacer en métodos de detección y de adaptación de modelos en casos donde no se cuente con suficientes datos. Además, desde DARPA²⁸ están en fase de desarrollo de un sistema genérico que permita tener cierta certeza sobre los contenidos multimedia que aparecen por internet. Su sistema se llama MediFor²⁹ y contiene tres indicadores donde comprueban diferentes integridades (digital, semántica y física) de las imágenes analizadas. Esta organización también se está preparando para la generación masiva de contenido sintético que se realice como servicio y sobre un mismo contexto, como puede ser una manifestación, combinando cada uno de los tipos de multimedia que hemos visto anteriormente.

VII. CONCLUSIONES

A lo largo de este artículo se ha tratado de dar una visión global del contenido sintético, los diversos usos que se pueden llegar a dar para cada una de los tipos de multimedia y métodos que pueden ser usados para protegerse y poder verificar este tipo de contenido, poniendo foco en las herramientas disponibles en internet. Creemos que es necesario prestar atención a este tipo de tecnologías y comenzar a pensar en cómo legislar sobre este contenido para evitar su uso fraudulento. Hay que tener en cuenta que es una tecnología con mucho

²⁸<https://www.darpa.mil>

²⁹<https://www.darpa.mil/program/media-forensics>



Figura 6: Algunos fotogramas con el resultado de aplicar FaceForensics++ [79]. Nótese que, cuando aparece más de una cara en el fotograma, FaceForensics++ solamente es capaz de detectar la cara más próxima. Vídeos extraídos del canal de YouTube FaceToFake (<https://tinyurl.com/uquu7sn>), que se dedica a producir *deepfakes* haciendo uso de la herramienta DeepFaceLab [85].

potencial pero tiene limitaciones: las más importantes son el cambio de idioma de un modelo preentrenado y la falta de conjuntos de datos que sean de utilidad en el entrenamiento de nuevos modelos tanto para la generación como la detección de contenido sintético.

REFERENCIAS

- [1] S. Marsland, *Machine Learning - An Algorithmic Perspective*, ser. Chapman and Hall / CRC machine learning and pattern recognition series. CRC Press, 2009.
- [2] I. J. Goodfellow, Y. Bengio, and A. C. Courville, "Deep Learning," *MIT Press*, 2016.
- [3] D. K. Bhattacharyya and J. K. Kalita, *Network Anomaly Detection: A Machine Learning Perspective*. Chapman & Hall/CRC, 2013.
- [4] M. H. Bhuyan, D. K. Bhattacharyya, and J. K. Kalita, *Network Traffic Anomaly Detection and Prevention - Concepts, Techniques, and Tools*, ser. Computer Communications and Networks. Springer, 2017.
- [5] F. Iglesias and T. Zseby, "Analysis of network traffic features for anomaly detection," *Machine Learning*, vol. 101, no. 1-3, pp. 59–84, 2015.
- [6] B. Cakir and E. Dogdu, "Malware classification using deep learning methods," in *ACM Southeast Regional Conference*. ACM, 2018, pp. 10:1–10:5.
- [7] L. Liu, B. Wang, B. Yu, and Q. Zhong, "Automatic malware classification and new malware detection using machine learning," *Frontiers of IT & EE*, vol. 18, no. 9, pp. 1336–1347, 2017.
- [8] N. Peiravian and X. Zhu, "Machine Learning for Android Malware Detection Using Permission and API Calls," in *ICTAI*. IEEE Computer Society, 2013, pp. 300–305.
- [9] Z. Li, D. Zou, S. Xu, X. Ou, H. Jin, S. Wang, Z. Deng, and Y. Zhong, "VulDeePecker: A Deep Learning-Based System for Vulnerability Detection," in *NDSS*. The Internet Society, 2018.
- [10] F. Wu, J. Wang, J. Liu, and W. Wang, "Vulnerability detection with deep learning," in *2017 3rd IEEE International Conference on Computer and Communications (ICCC)*, Dec 2017, pp. 1298–1302.
- [11] G. Grieco, G. L. Grinblat, L. C. Uzal, S. Rawat, J. Feist, and L. Mounier, "Toward Large-Scale Vulnerability Discovery using Machine Learning," in *CODASPY*. ACM, 2016, pp. 85–96.
- [12] H. Wu, H. Wang, and Y. Shi, "Can Machine Learn Steganography? - Implementing LSB Substitution and Matrix Coding Steganography with Feed-Forward Neural Networks," *CoRR*, vol. abs/1606.05294, 2016.
- [13] D. Volkhonskiy, I. Nazarov, B. Borisenko, and E. Burnaev, "Steganographic Generative Adversarial Networks," *CoRR*, vol. abs/1703.05502, 2017.
- [14] J. Hayes and G. Danezis, "Generating steganographic images via adversarial training," in *NIPS*, 2017, pp. 1954–1963.
- [15] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. C. Courville, and Y. Bengio, "Generative Adversarial Networks," *CoRR*, vol. abs/1406.2661, 2014.
- [16] C. Yinka-Banjo and O.-A. Ugot, "A review of generative adversarial networks and its application in cybersecurity," *Artificial Intelligence Review*, Jun. 2019. [Online]. Available: <https://doi.org/10.1007/s10462-019-09717-4>
- [17] I. A. Corley, J. Lwowski, and J. Hoffman, "Destruction of Image Steganography using Generative Adversarial Networks," *CoRR*, vol. abs/1912.10070, 2019.
- [18] S. Mahdaviyar and A. A. Ghorbani, "Application of deep learning to cybersecurity: A survey," *Neurocomputing*, vol. 347, pp. 149–176, 2019.
- [19] A. Handa, A. Sharma, and S. K. Shukla, "Machine learning in cybersecurity: A review," *Wiley Interdiscip. Rev. Data Min. Knowl. Discov.*, vol. 9, no. 4, 2019.
- [20] Z. Pan, W. Yu, X. Yi, A. Khan, F. Yuan, and Y. Zheng, "Recent progress on generative adversarial networks (gans): A survey," *IEEE Access*, vol. 7, pp. 36 322–36 333, 2019.
- [21] M. O. Khurshed, D. Saeed, and A. M. Khan, "Generative Adversarial Networks: A Survey of Techniques and Methods," in *Lecture Notes on Data Engineering and Communications Technologies*. Springer International Publishing, Aug. 2019, pp. 490–498. [Online]. Available: https://doi.org/10.1007/978-3-030-24643-3_58
- [22] Y. Cao, L. Jia, Y. Chen, N. Lin, C. Yang, B. Zhang, Z. Liu, X. Li, and H. Dai, "Recent Advances of Generative Adversarial Networks in Computer Vision," *IEEE Access*, vol. 7, pp. 14 985–15 006, 2019.
- [23] D. Brugioni, *Photo Fakery: The History and Techniques of Photographic Deception and Manipulation*. Brassey's, 1999. [Online]. Available: <https://books.google.es/books?id=3t1TAAAMA AJ>
- [24] L. Zheng, Y. Zhang, and V. L. L. Thing, "A survey on image tampering and its detection in real-world photos," *J. Visual Communication and Image Representation*, vol. 58, pp. 380–399, 2019.
- [25] J. Sharma and R. Sharma, "Analysis of Key Photo Manipulation Cases and their Impact on Photography," 2019.
- [26] S. Rosenbaum, "What is Synthetic Media?" <https://www.mediapost.com/publications/article/341074/what-is-synthetic-media.html>, 2020.
- [27] M. M. Waldrop, "News Feature: The genuine problem of fake news," *Proc. Natl. Acad. Sci. U.S.A.*, vol. 114, no. 48, pp. 12 631–12 634, 2017.
- [28] Corentin Jemine, "Automatic Multispeaker Voice Cloning," Master's thesis, Université de Liège, Liège, Belgique, 2019, <https://hdl.handle.net/2268.2/6801>.
- [29] Corentin Jemine, "Clone a voice in 5 seconds to generate arbitrary speech in real-time," <https://github.com/CorentinJ/Real-Time-Voice-Cloning>, 2019.
- [30] Y. Jia, Y. Zhang, R. J. Weiss, Q. Wang, J. Shen, F. Ren, Z. Chen,

- P. Nguyen, R. Pang, I. Lopez-Moreno, and Y. Wu, "Transfer Learning from Speaker Verification to Multispeaker Text-To-Speech synthesis," in *NeurIPS*, 2018, pp. 4485–4495.
- [31] N. Kalchbrenner, E. Elsen, K. Simonyan, S. Noury, N. Casagrande, E. Lockhart, F. Stimberg, A. van den Oord, S. Dieleman, and K. Kavukcuoglu, "Efficient Neural Audio Synthesis," in *ICML*, ser. Proceedings of Machine Learning Research, vol. 80. PMLR, 2018, pp. 2415–2424.
- [32] J. Shen, R. Pang, R. J. Weiss, M. Schuster, N. Jaitly, Z. Yang, Z. Chen, Y. Zhang, Y. Wang, R. Ryan, R. A. Saurous, Y. Agiomyrgiannakis, and Y. Wu, "Natural TTS Synthesis by Conditioning Wavenet on MEL Spectrogram Predictions," in *ICASSP*. IEEE, 2018, pp. 4779–4783.
- [33] L. Wan, Q. Wang, A. Papir, and I. Lopez-Moreno, "Generalized End-to-End loss for Speaker Verification," in *ICASSP*. IEEE, 2018, pp. 4879–4883.
- [34] Y. Chen and H. C. Ma, "Biometric Authentication Under Threat: Liveness Detection Hacking," in *Black Hat*, 2019.
- [35] A. Radford, K. Narasimhan, T. Salimans, and I. Sutskever, "Improving language understanding by generative pre-training," URL https://s3-us-west-2.amazonaws.com/openai-assets/researchcovers/languageunsupervised/language_understanding_paper.pdf, 2018.
- [36] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, and I. Sutskever, "Language models are unsupervised multitask learners," *OpenAI Blog*, vol. 1, no. 8, p. 9, 2019.
- [37] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei, "Language models are few-shot learners," 2020.
- [38] N. S. Keskar, B. McCann, L. R. Varshney, C. Xiong, and R. Socher, "CTRL: A Conditional Transformer Language Model for Controllable Generation," *CoRR*, vol. abs/1909.05858, 2019.
- [39] R. Zellers, A. Holtzman, H. Rashkin, Y. Bisk, A. Farhadi, F. Roesner, and Y. Choi, "Defending Against Neural Fake News," in *NeurIPS*, 2019, pp. 9051–9062.
- [40] T. Karras, S. Laine, and T. Aila, "A Style-Based Generator Architecture for Generative Adversarial Networks," in *CVPR*. Computer Vision Foundation / IEEE, 2019, pp. 4401–4410.
- [41] T. Karras, S. Laine, M. Aittala, J. Hellsten, J. Lehtinen, and T. Aila, "StyleGAN - Official Tensorflow Implementation," <https://github.com/NVlabs/stylegan>, 2018.
- [42] A. Rössler, D. Cozzolino, L. Verdoliva, C. Riess, J. Thies, and M. Nießner, "Flickr-Faces-HQDataset (FFHQ)," <https://github.com/NVlabs/ffhq-dataset>, 2019.
- [43] T. Karras, S. Laine, M. Aittala, J. Hellsten, J. Lehtinen, and T. Aila, "Analyzing and Improving the Image Quality of StyleGAN," *CoRR*, vol. abs/1912.04958, 2019.
- [44] —, "StyleGAN2 - Official Tensorflow Implementation," <https://github.com/NVlabs/stylegan2>, 2018.
- [45] T. Karras, M. Aittala, J. Hellsten, S. Laine, J. Lehtinen, and T. Aila, "Training generative adversarial networks with limited data," 2020.
- [46] T. Karras, T. Aila, S. Laine, and J. Lehtinen, "Progressive Growing of GANs for Improved Quality, Stability, and Variation," in *ICLR*. OpenReview.net, 2018.
- [47] D. Bitouk, N. Kumar, S. Dhillon, P. N. Belhumeur, and S. K. Nayar, "Face swapping: automatically replacing faces in photographs," *ACM Trans. Graph.*, vol. 27, no. 3, p. 39, 2008.
- [48] J. Thies, M. Zollhöfer, M. Stamminger, C. Theobalt, and M. Nießner, "Face2Face: real-time face capture and reenactment of RGB videos," *Commun. ACM*, vol. 62, no. 1, pp. 96–104, 2019.
- [49] R. Tolosana, R. Vera-Rodríguez, J. Fierrez, A. Morales, and J. Ortega-García, "DeepFakes and Beyond: A Survey of Face Manipulation and Fake Detection," *CoRR*, vol. abs/2001.00179, 2020.
- [50] deepfakes, "Deepfakes Software For All," <https://github.com/deepfakes/faceswap>, 2019.
- [51] G. Patrini, "The State of deepfakes 2019," <https://deeptacelabs.com/mapping-the-deepfake-landscape>, 2019.
- [52] M. Todisco, X. Wang, V. Vestman, M. Sahidullah, H. Delgado, A. Nautsch, J. Yamagishi, N. W. D. Evans, T. Kinnunen, and K. A. Lee, "ASVspoof 2019: Future Horizons in Spoofed and Fake Audio Detection," *CoRR*, vol. abs/1904.05441, 2019.
- [53] Dessa, "Using temporal convolution to detect Audio Deepfakes," <https://github.com/dessa-public/fake-voice-detection>, 2019.
- [54] E. C. Garrido-Merchán, C. Puente, and R. Palacios, "Fake News Detection by means of Uncertainty Weighted Causal Graphs," *CoRR*, vol. abs/2002.01065, 2020.
- [55] Y. Ren and J. Zhang, "HGAT: Hierarchical Graph Attention Network for Fake News Detection," *CoRR*, vol. abs/2002.04397, 2020.
- [56] M. H. Goldani, S. Momtazi, and R. Safabakhsh, "Detecting Fake News with Capsule Neural Networks," *CoRR*, vol. abs/2002.01030, 2020.
- [57] A. Bagade, A. Pale, S. Sheth, M. Agarwal, S. Chakrabarti, K. Chebrolo, and S. Sudarshan, "The Kauwa-Kaate Fake News Detection System: Demo," in *COMAD/CODS*. ACM, 2020, pp. 302–306.
- [58] K. Shu, D. Mahudeswaran, and H. Liu, "FakeNewsTracker: a tool for fake news collection, detection, and visualization," *Computational & Mathematical Organization Theory*, vol. 25, no. 1, pp. 60–71, 2019.
- [59] K. Shu, L. Cui, S. Wang, D. Lee, and H. Liu, "dFEND: Explainable Fake News Detection," in *KDD*. ACM, 2019, pp. 395–405.
- [60] R. Zellers, A. Holtzman, H. Rashkin, Y. Bisk, A. Farhadi, F. Roesner, and Y. Choi, "Code for Defending Against Neural Fake News," <https://github.com/rowanz/grover>, 2019.
- [61] S. Gehrmann, H. Strobelt, and A. M. Rush, "GLTR: Statistical Detection and Visualization of Generated Text," in *ACL (3)*. Association for Computational Linguistics, 2019, pp. 111–116.
- [62] H. Strobelt and S. Gehrmann, "Giant Language Model Test Room," <https://github.com/HendrikStrobelt/detecting-fake-text>, 2019.
- [63] P. Korus, "Digital image integrity - a survey of protection and verification techniques," *Digit. Signal Process.*, vol. 71, pp. 1–26, 2017.
- [64] S. Wang, O. Wang, A. Owens, R. Zhang, and A. A. Efros, "Detecting Photoshopped Faces by Scripting Photoshop," *CoRR*, vol. abs/1906.05856, 2019.
- [65] Y. Li, M. Chang, and S. Lyu, "In Ictu Oculi: Exposing AI Created Fake Videos by Detecting Eye Blinking," in *WIFS*. IEEE, 2018, pp. 1–7.
- [66] T. Miyato, T. Kataoka, M. Koyama, and Y. Yoshida, "Spectral Normalization for Generative Adversarial Networks," in *ICLR*. OpenReview.net, 2018.
- [67] M. G. Bellemare, I. Danihelka, W. Dabney, S. Mohamed, B. Lakshminarayanan, S. Hoyer, and R. Munos, "The Cramer Distance as a Solution to Biased Wasserstein Gradients," *CoRR*, vol. abs/1705.10743, 2017.
- [68] M. Binkowski, D. J. Sutherland, M. Arbel, and A. Gretton, "Demystifying MMD GANs," in *ICLR (Poster)*. OpenReview.net, 2018.
- [69] R. Wang, L. Ma, F. Juefei-Xu, X. Xie, J. Wang, and Y. Liu, "FakeSpotter: A simple Baseline for Spotting AI-Synthesized Fake Faces," *CoRR*, vol. abs/1909.06122, 2019.
- [70] M. Liu, Y. Ding, M. Xia, X. Liu, E. Ding, W. Zuo, and S. Wen, "STGAN: A Unified Selective Transfer Network for Arbitrary Image Attribute Editing," in *CVPR*. Computer Vision Foundation / IEEE, 2019, pp. 3673–3682.
- [71] D. Guera and E. J. Delp, "Deepfake Video Detection Using Recurrent Neural Networks," in *AVSS*. IEEE, 2018, pp. 1–6.
- [72] R. C. Bolles, J. B. Burns, M. Graciarena, A. Kathol, A. Lawson, M. McLaren, and T. Mensink, "Spotting Audio-Visual Inconsistencies (SAVI) in Manipulated Video," in *CVPR Workshops*. IEEE Computer Society, 2017, pp. 1907–1914.
- [73] X. Yang, Y. Li, and S. Lyu, "Exposing Deep Fakes Using Inconsistent Head Poses," in *ICASSP*. IEEE, 2019, pp. 8261–8265.
- [74] T. T. Nguyen, C. M. Nguyen, D. T. Nguyen, D. T. Nguyen, and S. Nahavandi, "Deep Learning for Deepfakes Creation and Detection," *CoRR*, vol. abs/1909.11573, 2019.
- [75] L. Verdoliva, "Media Forensics and Deepfakes: an overview," *CoRR*, vol. abs/2001.06564, 2020.
- [76] B. Dolhansky, R. Howes, B. Pflaum, N. Baram, and C. Canton-Ferrer, "The Deepfake Detection Challenge (DFDC) preview dataset," *CoRR*, vol. abs/1910.08854, 2019.
- [77] Y. Li, X. Yang, P. Sun, H. Qi, and S. Lyu, "Celeb-DF: A New Dataset for DeepFake Forensics," *CoRR*, vol. abs/1909.12962, 2019.
- [78] A. Rössler, D. Cozzolino, L. Verdoliva, C. Riess, J. Thies, and M. Nießner, "FaceForensics++: Learning to Detect Manipulated Facial Images," *CoRR*, vol. abs/1901.08971, 2019.
- [79] A. Rössler, D. Cozzolino, L. Verdoliva, C. Riess, J. Thies, and M. Nießner, "Github of the FaceForensics dataset," <https://github.com/ondyari/FaceForensics>, 2019.
- [80] M. Kowalski, "3D face swapping implemented in Python," <https://github.com/MarekKowalski/FaceSwap>, 2018.
- [81] J. Thies, M. Zollhöfer, and M. Nießner, "Deferred neural rendering: image synthesis using neural textures," *ACM Trans. Graph.*, vol. 38, no. 4, pp. 66:1–66:12, 2019.
- [82] D. E. King, "Dlib-ml: A Machine Learning Toolkit," *Journal of Machine Learning Research*, vol. 10, pp. 1755–1758, 2009.
- [83] L. Huang, A. D. Joseph, B. Nelson, B. I. P. Rubinstein, and J. D. Tygar, "Adversarial machine learning," in *AISeC*. ACM, 2011, pp. 43–58.
- [84] P. Neekhar, S. Hussain, M. Jere, F. Koushanfar, and J. McAuley, "Adversarial Deepfakes: Evaluating Vulnerability of Deepfake Detectors to Adversarial Examples," 2020.
- [85] iperov, "DeepFaceLab is the leading software for creating deepfakes," <https://github.com/iperov/DeepFaceLab>, 2019.