Después de proteger la infraestructura y los datos, deberías preocuparte por tus modelos de IA.

Introducción al Adversarial Machine Learning.

Quiénes somos

Miguel Hernández Boza
Security Content Engineer
Sysdig
@MiguelHzBz

José Ignacio Escribano Pablos
Security & Machine Learning Researcher
BBVA Next Technologies
/in/josé-ignacio-escribano-pablos

Disclaimer

Todo lo que se muestra en esta charla es con **fines educativos**.

Nuestras opiniones personales no están relacionadas con nuestros actuales centros de trabajo.

*“Through 2022, 30% of all AI cyberattacks will leverage **training-data poisoning**, **AI model theft**, or **adversarial samples** to attack AI-powered systems.”*

https://www.microsoft.com/security/blog/2020/10/22/cyberattacks-against-machine-learning-systems-are-more-common-than-you-think/

Índice

1.
Machine Learning y ciberseguridad

AI Teams

Facebook’s ‘Red Team’ Hacks Its Own AI Programs

https://www.wired.com/story/facebooks-red-team-hacks-ai-programs

Blue Team

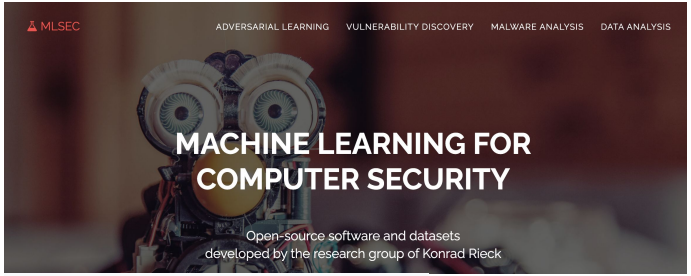

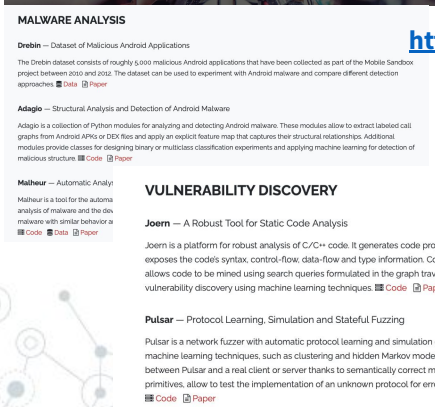

http://www.mlsec.org

Red Team

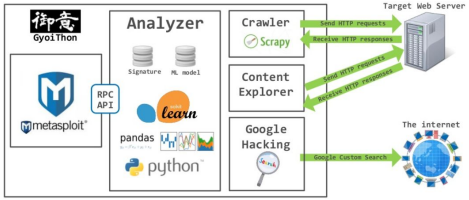

https://github.com/gyoisamurai/GyoiThon

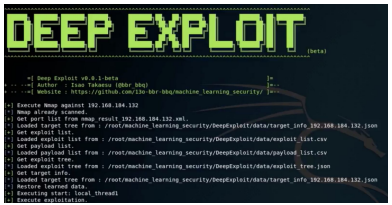

https://github.com/13o-bbr-bbq/machine_learning_security

https://medium.com/analytics-vidhya/deepfake-ai-explainer-and-examples-6d9e4bec55c0

AI Red Team

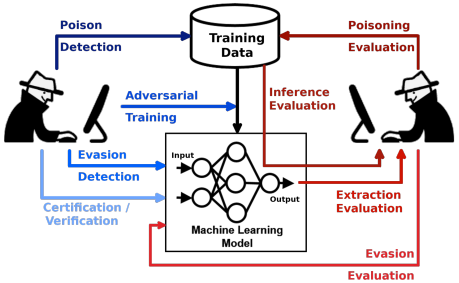

The Quiet Victories and False Promises of Machine Learning in Security

https://sysdig.com/blog/machine-learning-in-cybersecurity/

The MLSecOps Top 10

The MLSecOps Top 10 is an initiative that aims to further the field of machine learning security by identifying the top 10 most common vulnerabiliites in the machine learning lifecycle. This project aims to provide an evaluation of security vulnerabilities analogous to the "OWASP Top 10 Report" but with a focus on machine learning security.

https://ethical.institute/security.html

aws

SECURING YOUR MACHINE LEARNING MODELS

PHIL BASFORD

MAY 2022

http://thethirstyrobot.co.uk/OWASP-Suffolk-Securing-ML

2.
Machine Learning 101

Machine Learning 101

Inteligencia Artificial (AI)
Rama de las Ciencias de la Computación que se ocupa de la **simulación del comportamiento inteligente** en las computadoras.

Machine Learning (ML)
Disciplina de la Inteligencia Artificial relacionada con la implementación de **software que puede aprender de forma autónoma**.

Deep Learning (DL)
Campo del Machine Learning que trabaja con algoritmos **inspirados en la estructura y funciones del cerebro humano**, conocidos como **redes neuronales**.

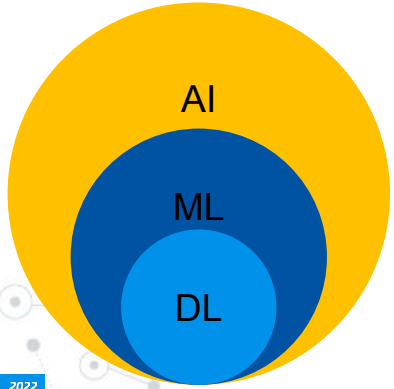

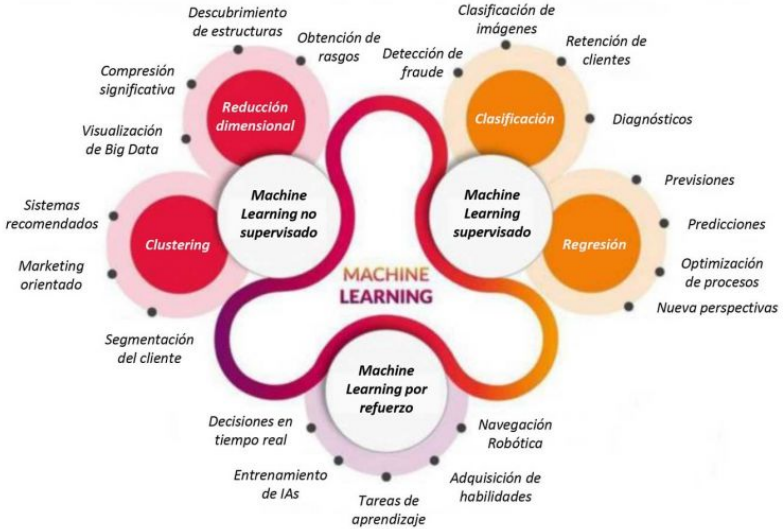

https://www.interempresas.net/MetalMecanica/Articulos/347471-Los-conceptos-de-Machine-Learning-y-Deep-Learning-en-la-industria.html

Machine Learning = Datos + Algoritmos

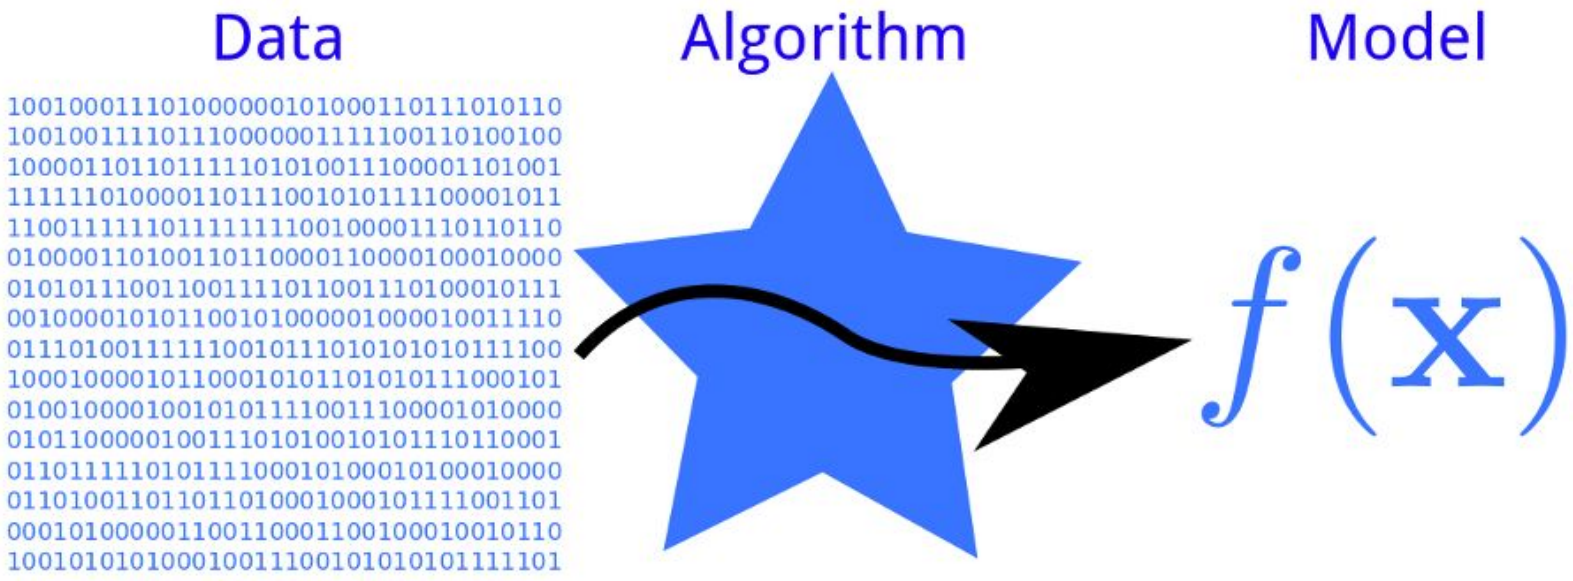

http://phdp.github.io/posts/2013-07-05-dtl.html

Clasificación y regresión

Clasificación

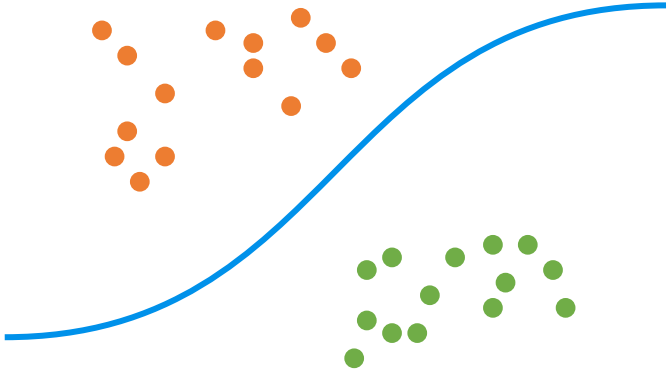

Regresión

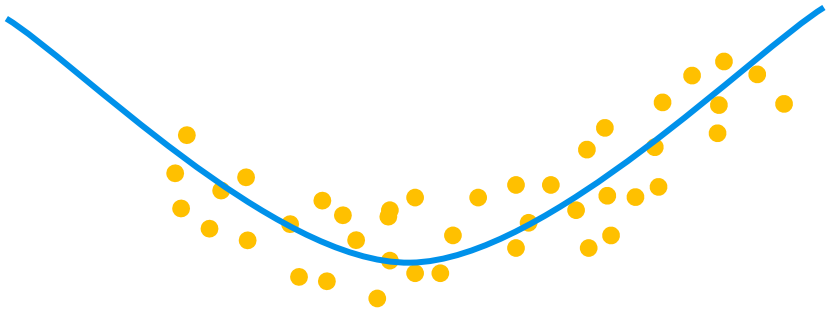

Datos y algoritmos

Repositorios de datos

- https://datasource.kapsarc.org/pages/home (energía, demografía, economía, …).
- https://www.kaggle.com/datasets (casi cualquier temática).
- http://usgovxml.com (servicios web del gobierno de EEUU).
- https://aws.amazon.com/es/datasets (varias temáticas).
- https://www.re3data.org (búsqueda por palabras).
- https://www.reddit.com/r/datasets (publicación y solicitud de distintos conjuntos de datos).
- http://www.secrepo.com (conjuntos de datos de seguridad).

Repositorios de imágenes

- **MNIST**: dígitos escritos a mano.
- **CIFAR10/CIFAR100**: imágenes de 32x32 con 10/100 categorías de objetos.
- **CelebA**: 200.000 imágenes con más de 40 atributos de famosos.
- **ImageNet**.
- **COCO** dataset.
- …

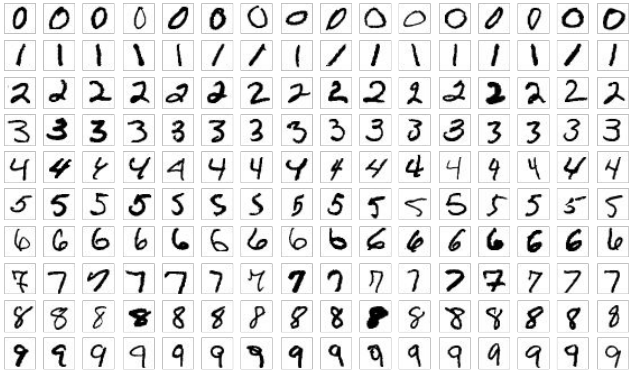

Datos y algoritmos

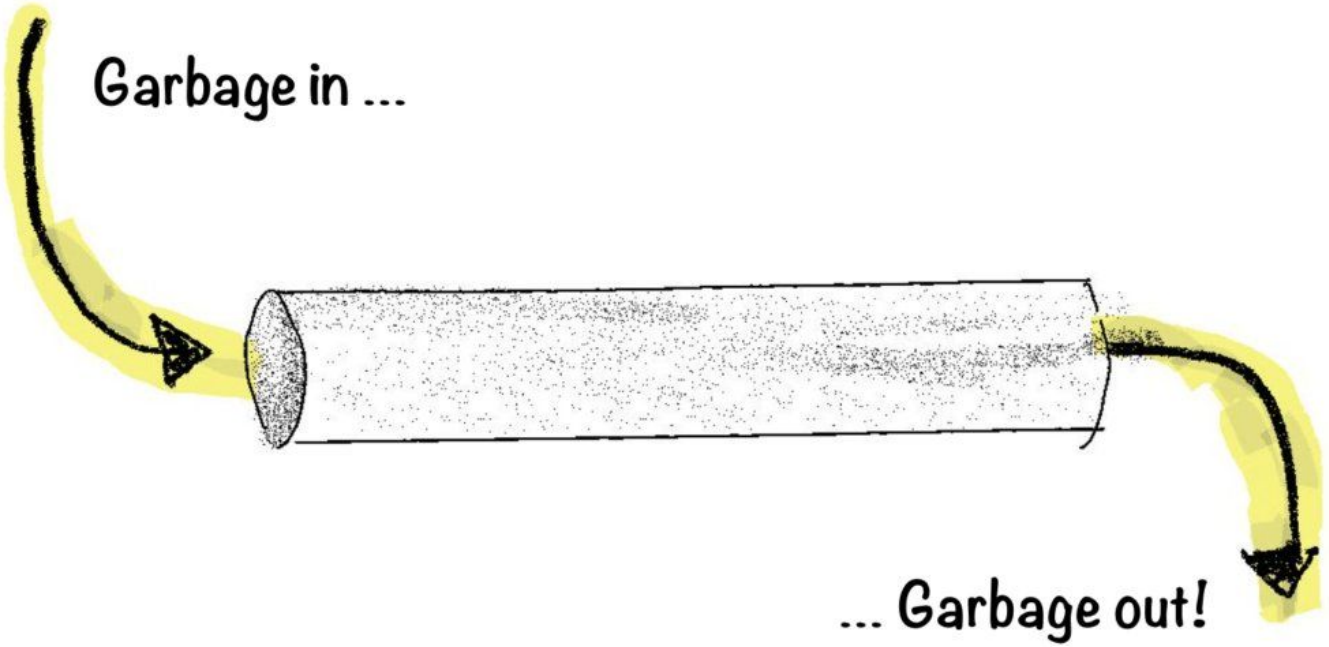

https://blog.owulveryck.info/2021/06/08/pov-a-streaming/communication-platform-for-the-data-mesh.html

Datos y algoritmos

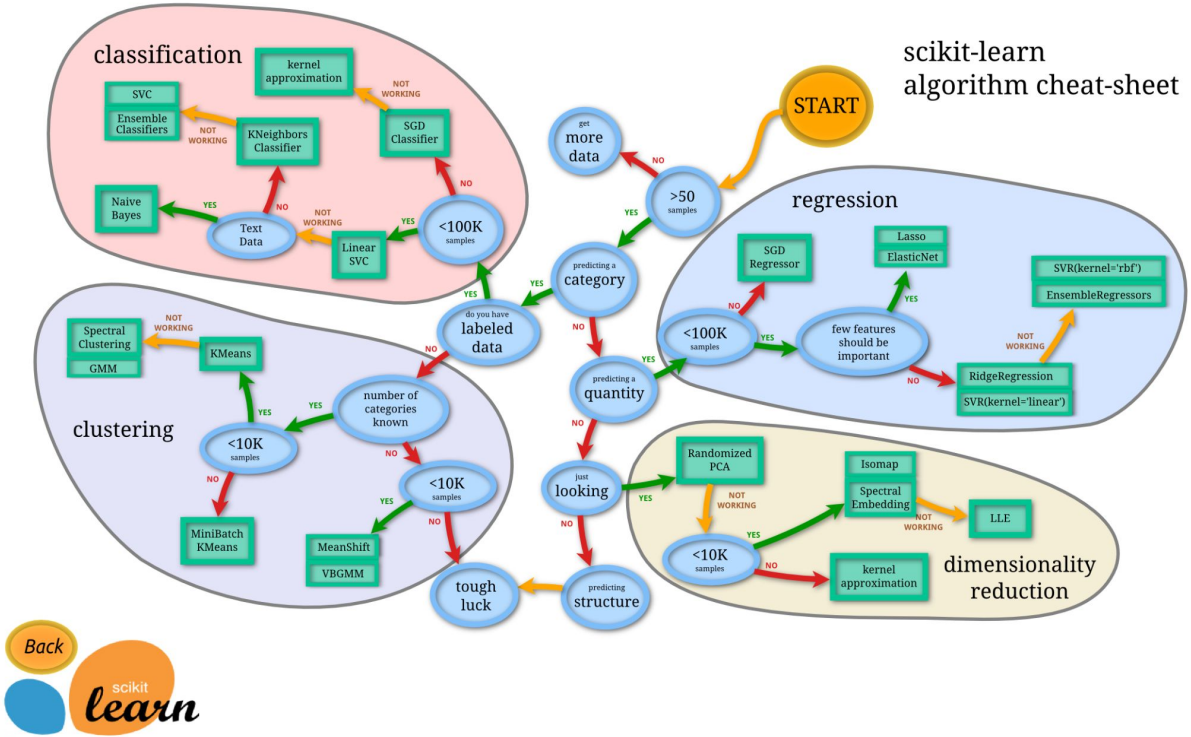

https://scikit-learn.org/stable/tutorial/machine_learning_map/index.html

Deep Learning

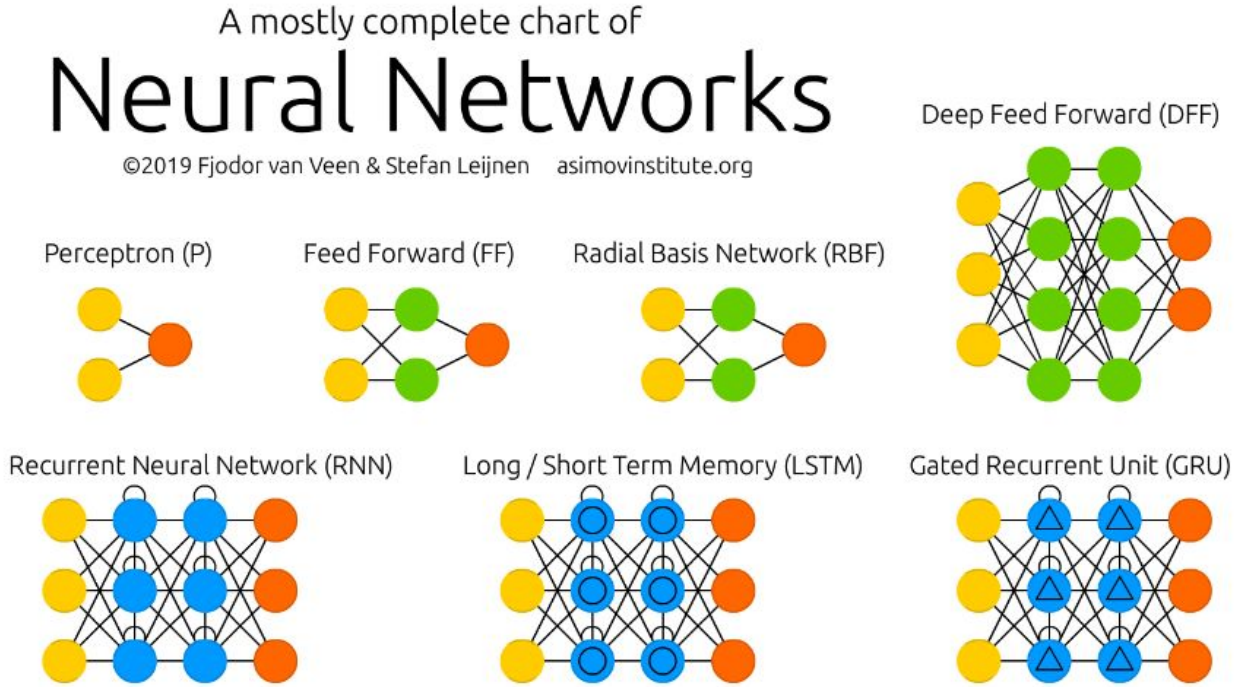

Infografía completa: https://www.asimovinstitute.org/neural-network-zoo

Entrenamiento del modelo

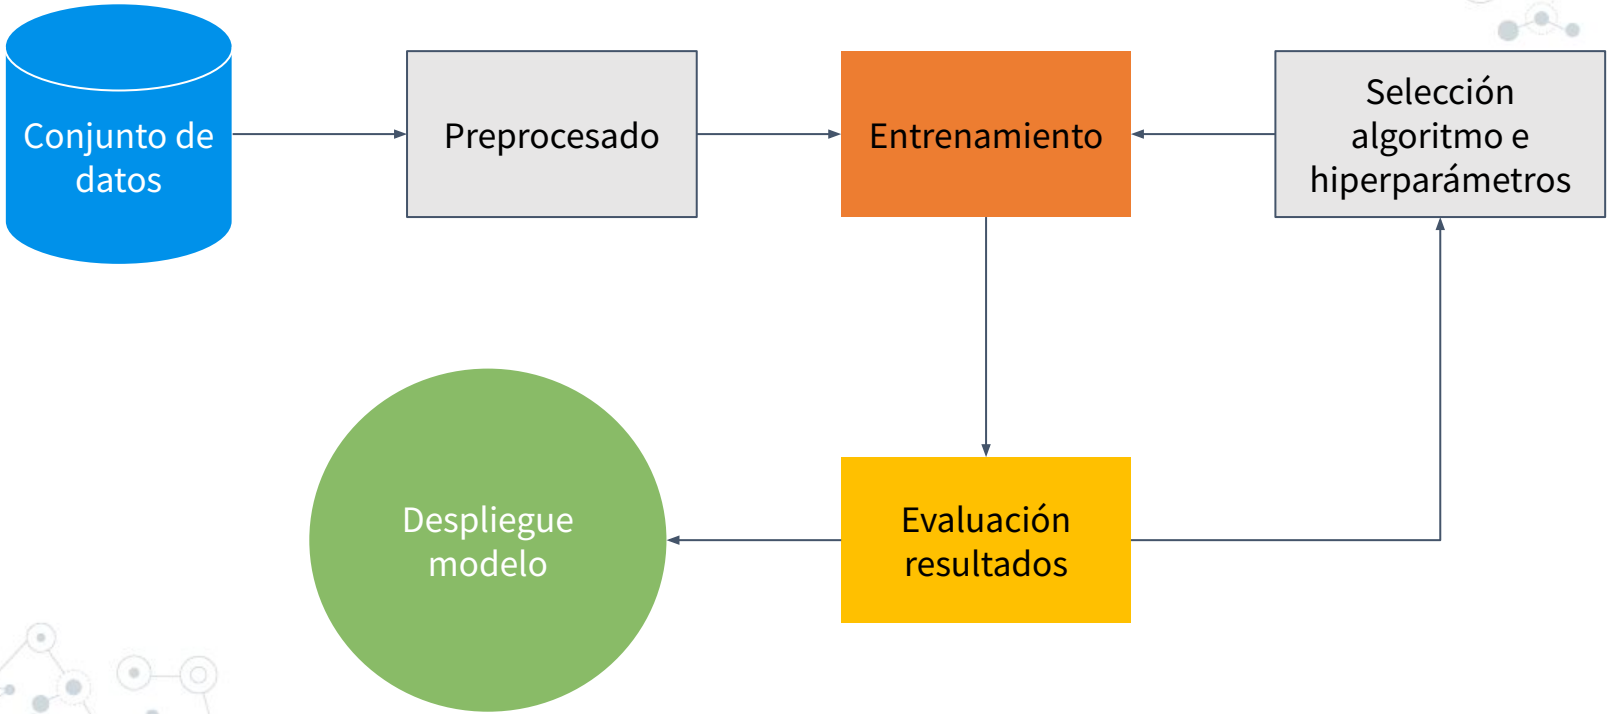

Algunas librerías/frameworks

3.
Adversarial Machine Learning

Adversarial Machine Learning

Rama del machine learning que trata de averiguar los **ataques** que puede sufrir un **modelo** en la presencia de un adversario malicioso y cómo **protegerse de ellos**.

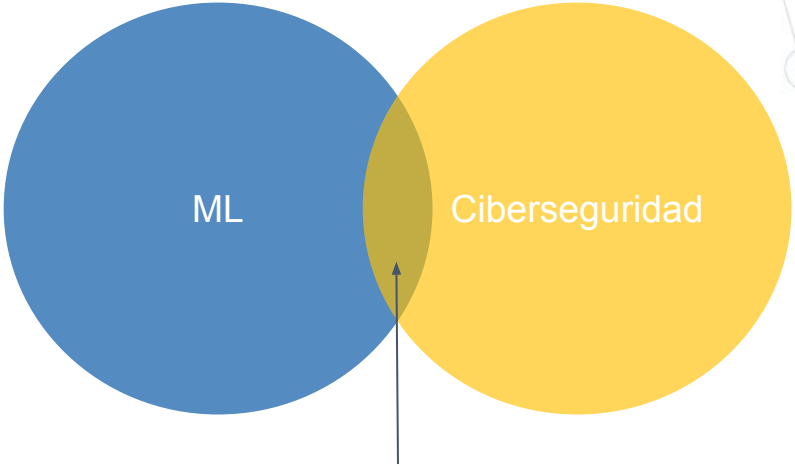

*“If you use **machine learning**, there is the risk for exposure, even **though the threat does not currently exist in your space**.”*

*“The **gap** between **machine learning and security** is definitely there.”*

Adversarial Machine Learning

Draft NISTIR 8269

A Taxonomy and Terminology of Adversarial Machine Learning

Elham Tabassi
Kevin J. Burns
Michael Hadjimichael
Andres D. Molina-Markham
Julian T. Sexton

This publication is available free of charge from:
https://doi.org/10.6028/NIST.IR.8269-draft

NIST
National Institute of Standards and Technology
U.S. Department of Commerce

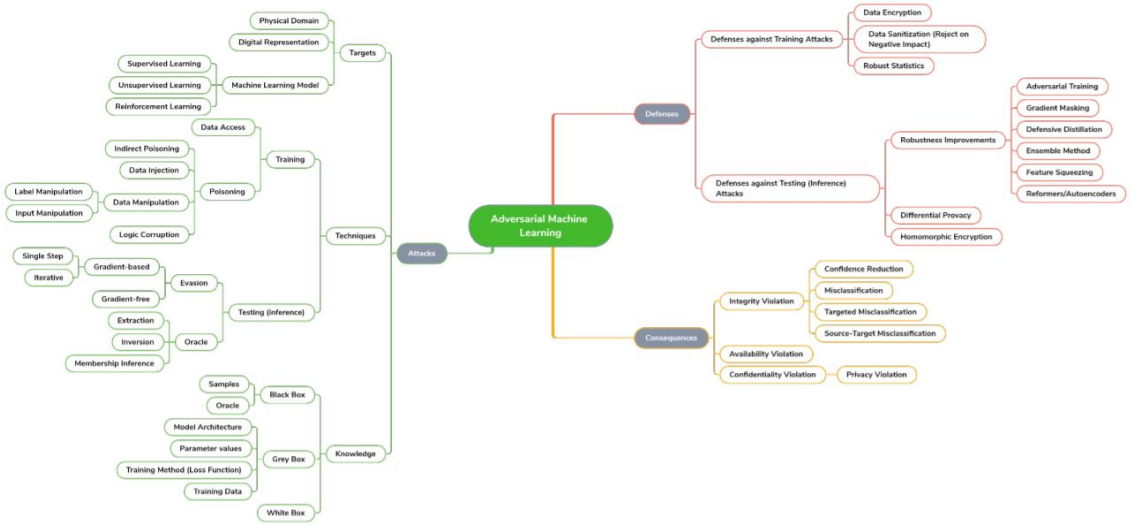

https://nvlpubs.nist.gov/nistpubs/ir/2019/NIST.IR.8269-draft.pdf

Adversarial Machine Learning

Reconnaissance	Initial Access	Execution	Persistence	Model Evasion	Exfiltration	Impact
Acquire OSINT information: (Sub Techniques) 1. Arxiv 2. Public blogs 3. Press Releases 4. Conference Proceedings 5. Github Repository 6. Tweets	Pre-trained ML model with backdoor	Execute unsafe ML models (Sub Techniques) 1. ML models from compromised sources 2. Pickle embedding	Execute unsafe ML models (Sub Techniques) 1. ML models from compromised sources 2. Pickle embedding	Evasion Attack (Sub Techniques) 1. Offline Evasion 2. Online Evasion	Exfiltrate Training Data (Sub Techniques) 1. Membership inference attack 2. Model inversion	Defacement
ML Model Discovery (Sub Techniques) 1. Reveal ML model ontology – 2. Reveal ML model family –	Valid account	Execution via API	Account Manipulation		Model Stealing	Denial of Service
Gathering datasets	Phishing	Traditional Software attacks	Implant Container Image	Model Poisoning	Insecure Storage 1. Model File 2. Training data	Stolen Intellectual Property
Exploit physcial environment	External remote services			Data Poisoning (Sub Techniques) 1. Tainting data from acquisition – Label corruption 2. Tainting data from open source supply chains 3. Tainting data from acquisition – Chaff data 4. Tainting data in training environment – Label corruption		Data Encrypted for Impact Defacement
Model Replication (Sub Techniques) 1. Exploit API – Shadow Model 2. Alter publicly available, pre-trained weights	Exploit public facing application					Stop System Shutdown/Reboot
Model Stealing	Trusted Relationship					

https://github.com/mitre/advmlthreatmatrix/blob/master/pages/adversarial-ml-threat-matrix.md#adversarial-ml-threat-matrix

Adversarial Machine Learning

MITRE | SOLVING PROBLEMS FOR A SAFER WORLD®

ABOUT CENTERS CAPABILITIES RESEA

Project Stories

https://www.mitre.org/publications/project-stories/creating-an-ai-red-team-to-protect-critical-infrastructure

CREATING AN AI RED TEAM TO PROTECT CRITICAL INFRASTRUCTURE

September 2019

Topics: Homeland Security, Artificial Intelligence, Machine Learning, Cybersecurity, Network Security

As our nation's critical infrastructure increasingly relies upon artificial intelligence, bad actors are finding ways to fool machine learning—with potentially dangerous consequences. Can AI red teams help to protect against such potential attacks?

We need AI Red Teams, NOW!

Tommy Shrove, Ph.D. Follow

Nov 22, 2020 · 6 min read ★

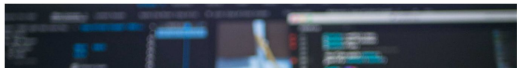

https://medium.com/disruptive-nerd/we-need-ai-red-teams-now-caaae45af22

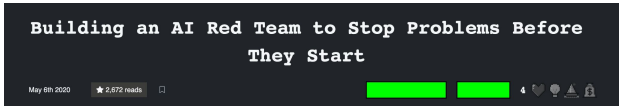

https://hackernoon.com/building-an-ai-red-team-to-stop-problems-before-they-start-9e6g32uj

Featured New

Why the Department of Defense Should Create an AI Red Team

September 7, 2021 0 Comments

Estimated Read Time: 5 Minutes

By Rena DeHenre

https://othjournal.com/2021/09/07/why-the-department-of-defense-should-create-an-ai-red-team/

DragonJAR 2022 SECURITY CONFERENCE

Adversarial Machine Learning

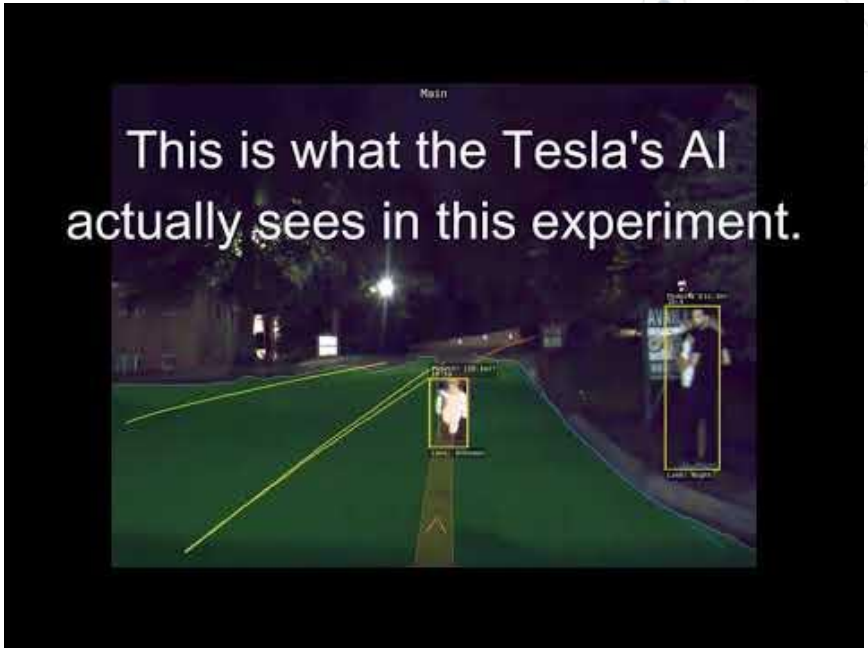

https://www.nassiben.com/phantoms

Adversarial Machine Learning

https://www.csail.mit.edu/news/fooling-neural-networks-w3d-printed-objects

https://www.youtube.com/watch?v=zQ_uMenoBCk

Adversarial Machine Learning

- **Ataques de caja negra:** el adversario sólo tiene acceso a las entradas y salidas del modelo.
- **Ataques de caja gris:** el ataque se encuentra en un punto intermedio entre los dos tipos de ataques anteriores.
- **Ataques de caja blanca:** el adversario tiene acceso a la arquitectura usada por el modelo, a los datos de entrenamiento, a los parámetros e hiperparámetros.

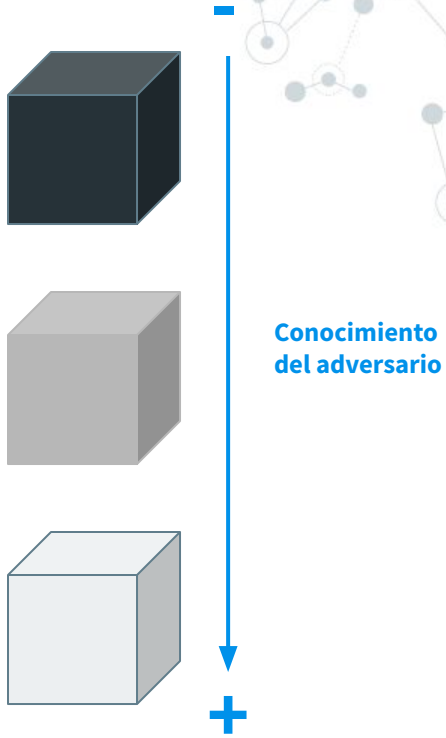

Adversarial Machine Learning

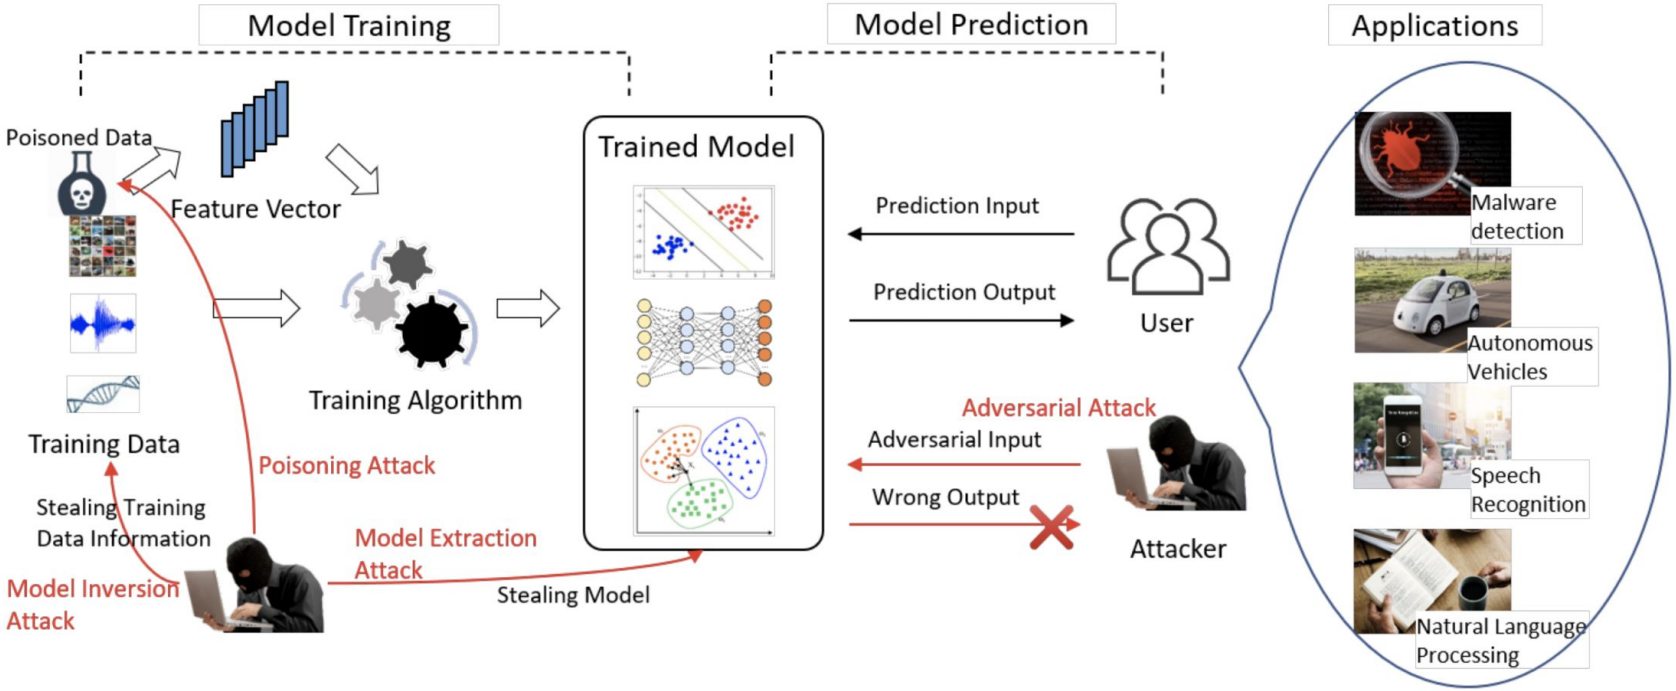

https://arxiv.org/abs/1911.12562

Adversarial Machine Learning

Ataques de **extracción**
(o robo de modelos)

Ataques de **inversión**

Ataques de **envenenamiento**

Ataques de **evasión**

3.1
Herramientas y frameworks

Herramientas y frameworks open source

Nombre	Tipo	Algoritmos	Tipos de ataques	Ataque/Defensa	Frameworks soportados
Cleverhans	Imagen	Deep Learning	Evasión	Ataque	Tensorflow, Keras, JAX
Foolbox	Imagen	Deep Learning	Evasión	Ataque	Tensorflow, PyTorch, JAX
ART	Cualquiera	Deep Learning, SVM, LR, etc.	Todos	Ambos	Tensorflow, Keras, Pytorch, Scikit Learn
TextAttack	Texto	Deep Learning	Evasión	Ataque	Keras, HuggingFace
Advertorch	Imagen	Deep Learning	Evasión	Ambos	----
AdvBox	Imagen	Deep Learning	Evasión	Ambos	PyTorch, Tensorflow, MxNet
DeepRobust	Imagen, grafos	Deep Learning	Evasión	Ambos	PyTorch
Counterfit	Cualquiera	Cualquiera	Evasión	Ataque	----
Adversarial Audio Examples	Audio	DeepSpeech	Evasión	Ataque	----

Adversarial Robustness Toolbox (ART)

- Adversarial Robustness Toolbox (https://github.com/Trusted-AI/adversarial-robustness-toolbox), abreviado como **ART**, es una librería opensource de Adversarial Machine Learning que permite comprobar la **robustez de los modelos de machine learning**.

- Está desarrollada en **Python** e implementa **ataques y defensas** de extracción, inversión, envenenamiento y evasión.

- ART soporta los **frameworks más populares**: Tensorflow, Keras, PyTorch, MxNet, ScikitLearn, entre muchos otros.

- No está limitada al uso de modelos que emplean **imágenes** como entrada, sino que soporta otros tipos de datos como **audio, vídeo, datos tabulares**, etc.

- Instalación con **pip**.


```
pip install adversarial-robustness-toolbox
```

Adversarial Robustness Toolbox (ART)

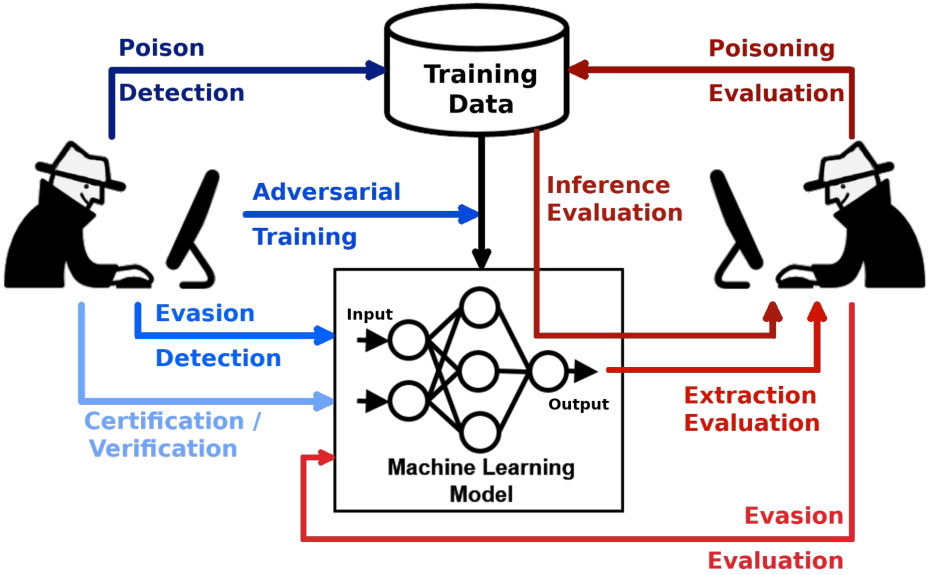

Adversarial Robustness Toolbox (ART)

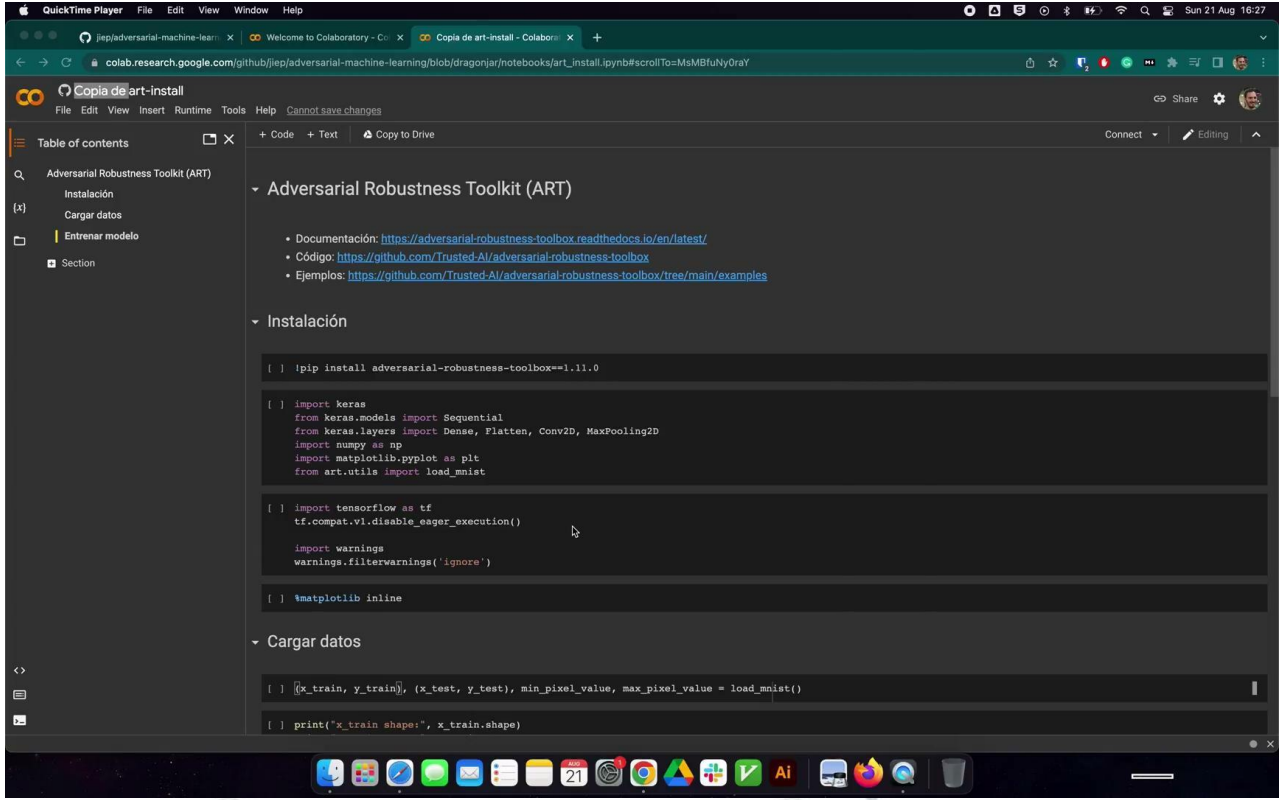

https://github.com/jiep/adversarial-machine-learning/blob/main/notebooks/art_install.ipynb

Counterfit

- Counterfit (https://github.com/Azure/counterfit) es una **CLI** escrita en Python y desarrollada por Microsoft.
- Desarrollada para **auditorías de seguridad sobre modelos de ML**.
- Implementa algoritmos de **evasión de caja negra**.
- Se basa en **ART y TextAttack**.

```
---------------------------------------------------
Microsoft
                                 __            _____ __
  _________  __  ______  / /____  _____/ __(_) /_
 / ___/ __ \/ / / / __ \/ __/ _ \/ ___/ /_/ / __/
/ /__/ /_/ / /_/ / / / / /_/  __/ /  / __/ / /
\___/\____/\__,_/_/ /_/\__/\___/_/  /_/ /_/\__/

                                                #ATML

---------------------------------------------------
```

list targets: lista modelos disponibles
list frameworks: lista frameworks de ataque disponibles
load <framework>: carga el framework
list attacks: lista ataques del framework seleccionado
interact <target>: selecciona el modelo objetivo
predict -i <ind>: predicción sobre la entrada ind
use <attack>: selecciona ataque
run: ejecuta ataque
scan: ejecuta ataque
show options: muestra opciones del ataque
set <param>=<value>: cambia el valor de param a value
save: guarda los resultados en json

3.2
Ataques y demos

https://github.com/jiep/adversarial-machine-learning

Ataques de extracción (o robo de modelos)

- Permiten a un adversario **robar los parámetros** de un modelo de machine learning.
- Se produce al realizar peticiones al modelo objetivo con **entradas preparadas para extraer la mayor cantidad de información posible** y con el conjunto de entradas y salidas entrenar un modelo llamado modelo sustituto.
- Permite además **realizar otros tipos de ataque** como evasión y/o inversión.

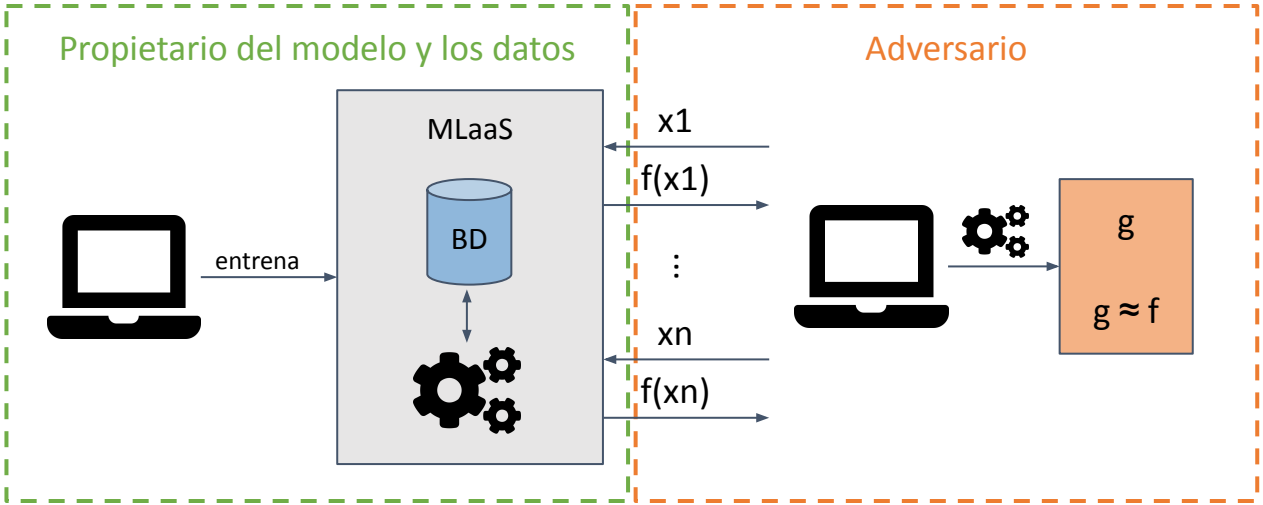

Ataques de extracción (o robo de modelos)

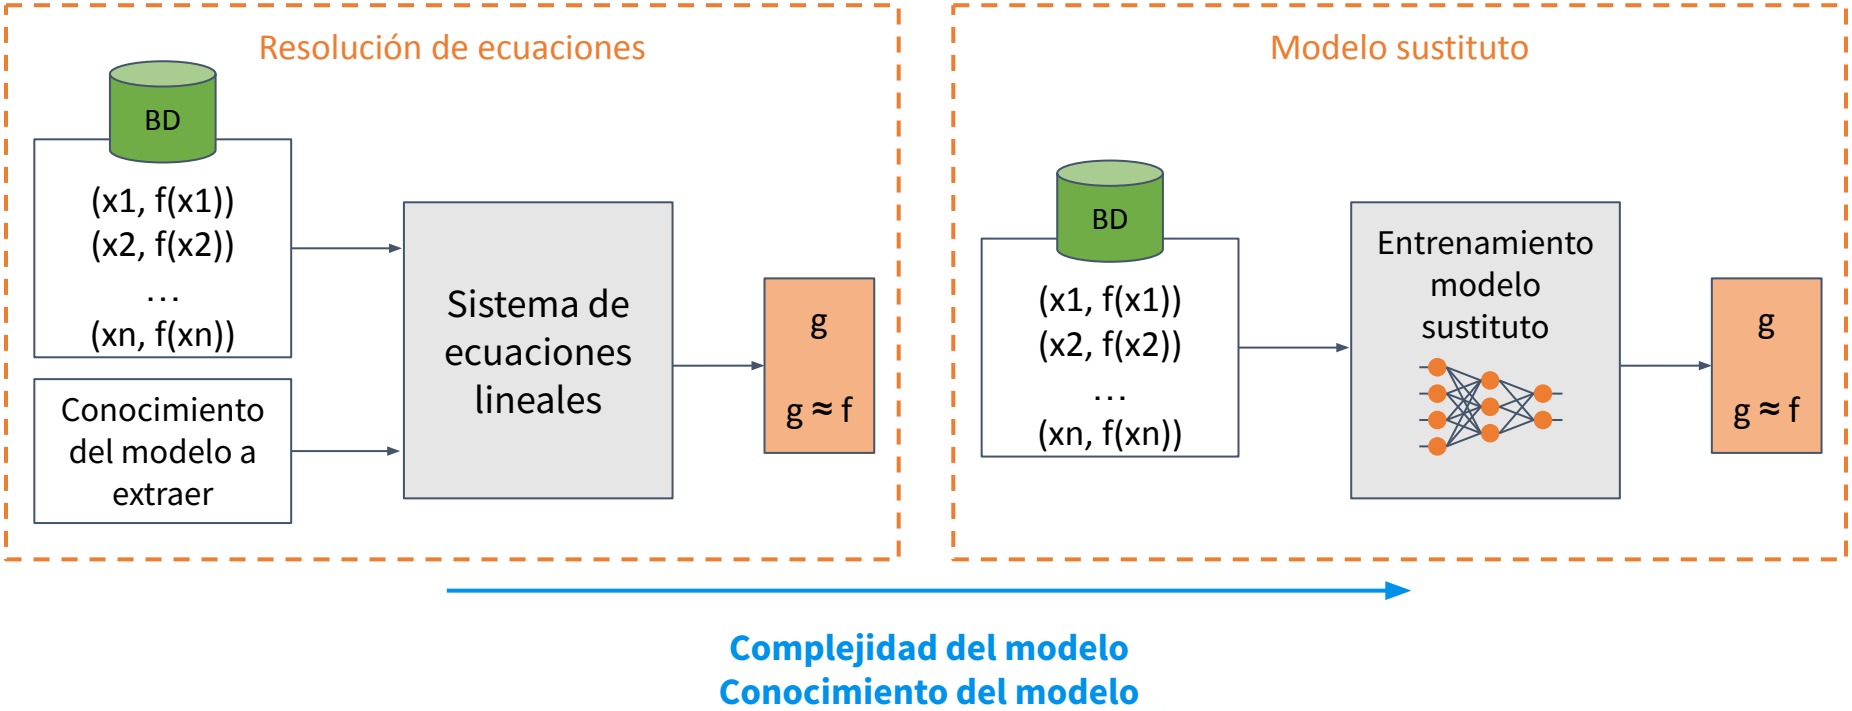

Ataques de extracción (o robo de modelos)
Limitaciones

- Entrenar un **modelo sustituto** es equivalente (en muchos casos) a entrenar un modelo desde cero.
- Muy **costoso** computacionalmente.
- **Limitaciones** en el número de peticiones.

Ataques de extracción (o robo de modelos)
Medidas defensivas

- **Redondeo** de los valores de salida.
- **Privacidad diferencial**.
- **Ensembles**.
- **Defensas específicas**
  - Arquitecturas específicas (https://arxiv.org/abs/1711.07221)
  - PRADA (https://arxiv.org/abs/1805.02628)
  - Adaptive Misinformation (https://arxiv.org/abs/1911.07100)
  - ...

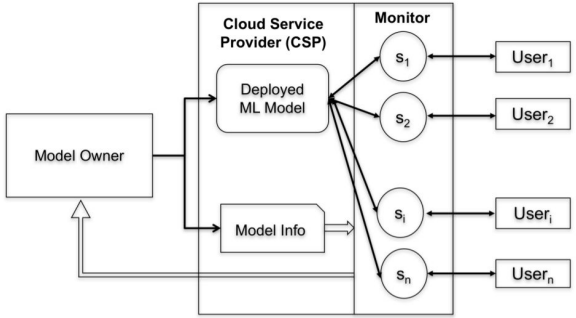

https://arxiv.org/abs/1711.07221

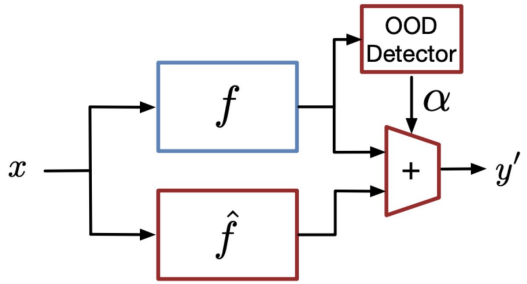

https://arxiv.org/abs/1911.07100

Ataques de extracción (o robo de modelos)

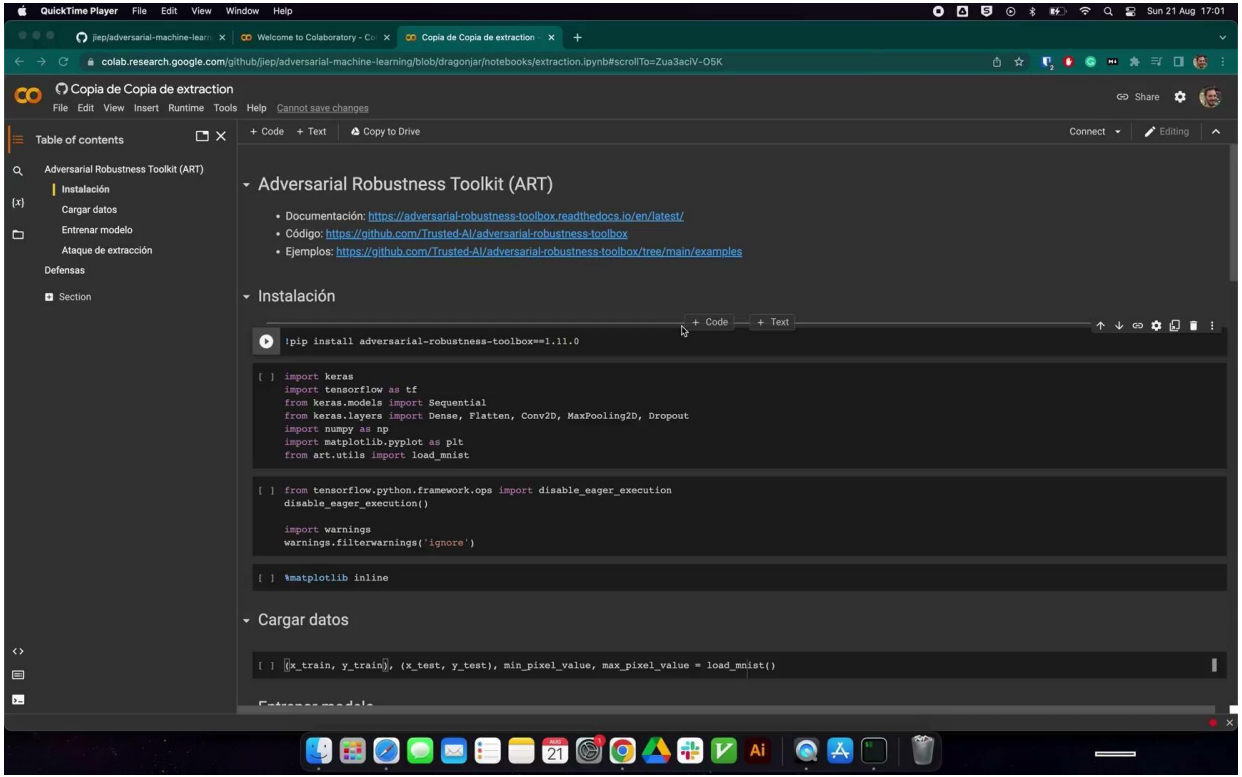

https://github.com/jiep/adversarial-machine-learning/blob/main/notebooks/extraction.ipynb

Ataques de inversión

- Tienen como objetivo **invertir el flujo de información** de un modelo de machine learning.
- Permiten a un adversario tener un **conocimiento del modelo que no pretendía ser compartido de forma explícita**.
- Incluye conocer los **datos de entrenamiento o información como propiedades estadísticas del modelo**.
- Se distinguen tres tipos:
  - **Membership Inference Attack** (MIA): un adversario trata de determinar si una muestra fue empleada como parte del entrenamiento.
  - **Property Inference Attack** (PIA): un adversario trata de extraer propiedades de carácter estadístico que no fueron explícitamente codificadas como características durante la fase de entrenamiento.
  - **Reconstrucción**: un adversario trata de recrear una o más muestras del conjunto de entrenamiento y/o sus correspondientes etiquetas. También llamados de inversión.

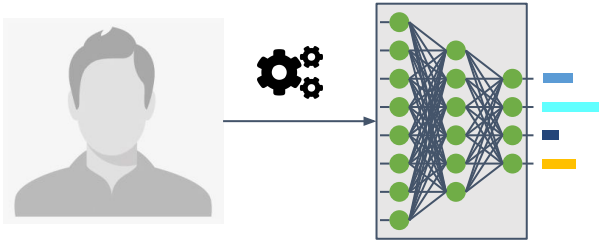

Inversión del modelo

https://dl.acm.org/doi/10.1145/2810103.2813677

Ataques de inversión
Causas del filtrado de información

- El **sobreentrenamiento** es una condición suficiente, pero no necesaria para realizar un ataque **MIA**. Incluso en modelos que generalizan bien es posible realizar un ataque MIA sobre un **subconjunto de los datos de entrenamiento** que son denominados registros vulnerables.

- La **complejidad de los datos y un número alto de clases** incrementa la posibilidad de ataques **MIA**.

- Las propuestas de **entrenamiento adversario robusto** incrementan las posibilidades de ataques **MIA**.

- Un modelo con una **alta potencia predictiva** es más propenso a **ataques de reconstrucción**.

Ataques de inversión
Medidas defensivas

- Uso de la **criptografía avanzada**. Entre las medidas se incluyen la **privacidad diferencial**, la **criptografía homomórfica** y la **computación multiparte segura**.
- Uso de técnicas de regularización como **Dropout** debido a la **relación entre sobreentrenamiento y privacidad**.
- La **compresión de modelos** se ha propuesto como defensa frente a ataques de reconstrucción.

Ataques de inversión

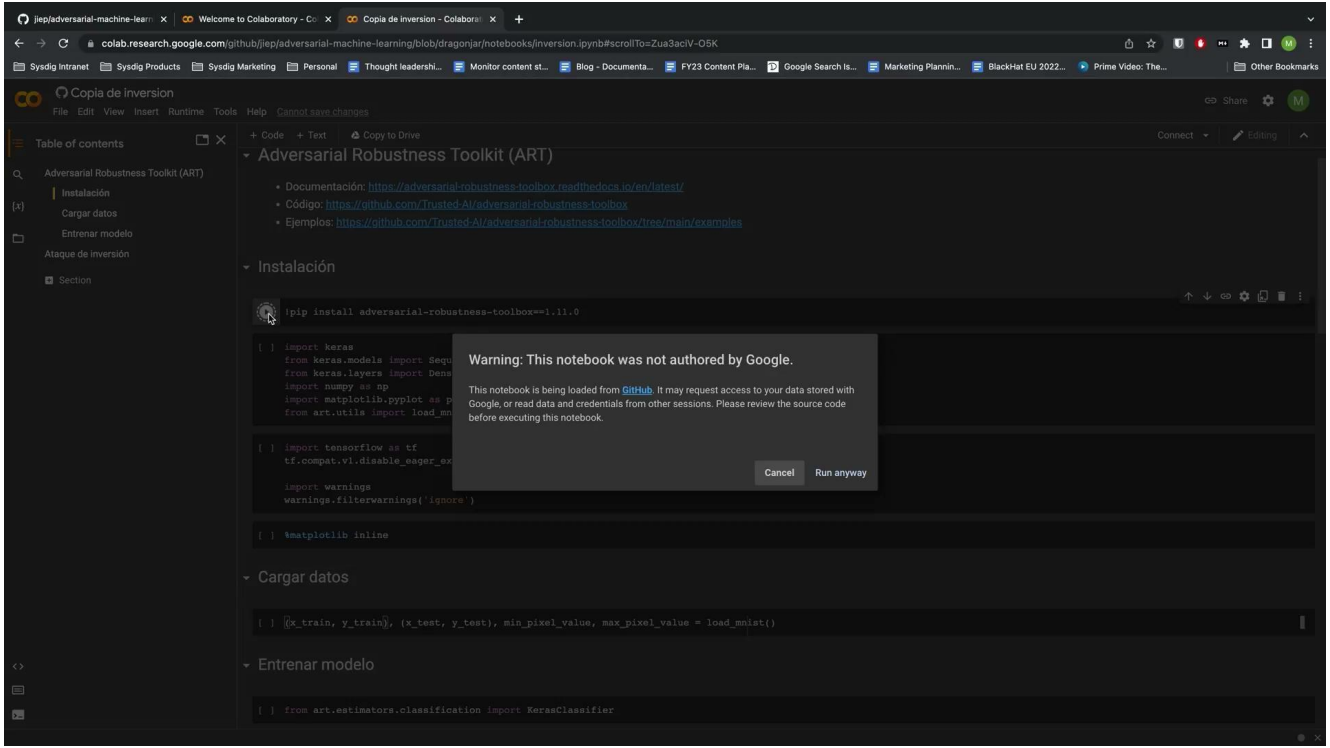

https://github.com/jiep/adversarial-machine-learning/blob/main/notebooks/inversion.ipynb

Ataques de envenenamiento

- Buscan **corromper el conjunto de entrenamiento** haciendo que un modelo de machine learning **reduzca su precisión**.
- Este ataque es **difícil de detectar** al realizarse sobre los datos de entrenamiento, puesto que el ataque se puede **propagar entre distintos modelos** al emplear los mismos datos.
- El adversario busca modificar la **frontera de decisión** y, como resultado, produciendo **predicciones incorrectas** o,
- Crear una **puerta trasera** en un modelo. El modelo se comporta de forma correcta (devolviendo las predicciones deseadas) en la mayoría de casos, **salvo en ciertas entradas especialmente creadas por el adversario que producen resultados no deseados**.

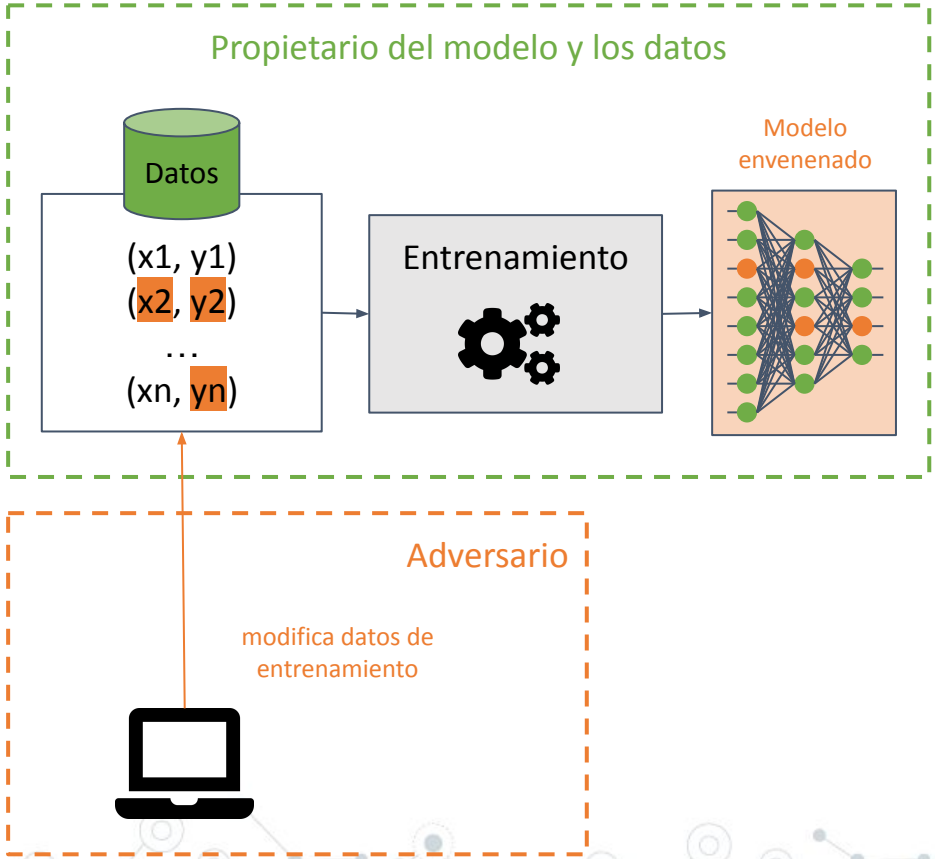

Ataques de envenenamiento

BadNets

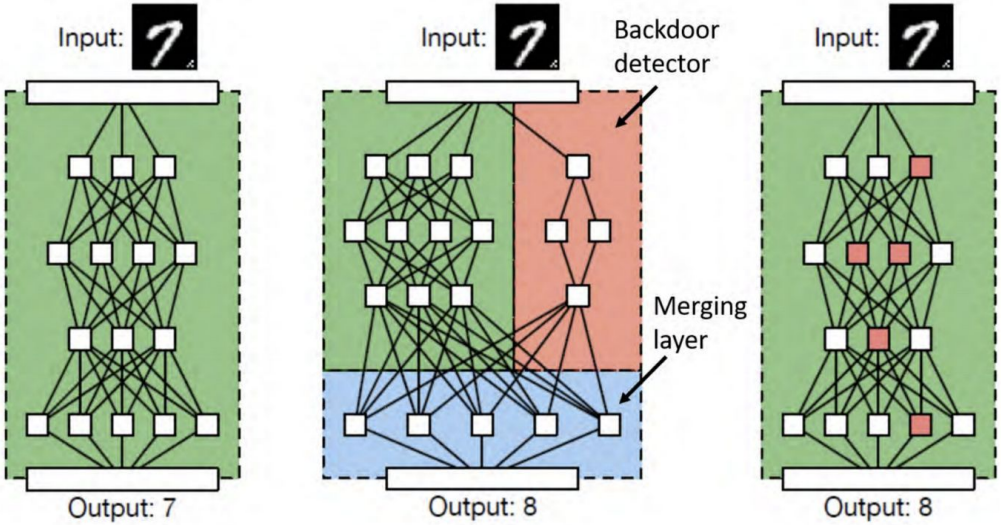

Disparadores


Original image


Single-Pixel Backdoor


Pattern Backdoor

https://arxiv.org/abs/1708.06733

Ataques de envenenamiento

https://arxiv.org/abs/1708.06733

Ataques de envenenamiento

- Las BadNets son capaces de **conservarse en un modelo**, aunque se **vuelvan a entrenar de nuevo para otra tarea** distinta a la del modelo original (*transfer learning*).

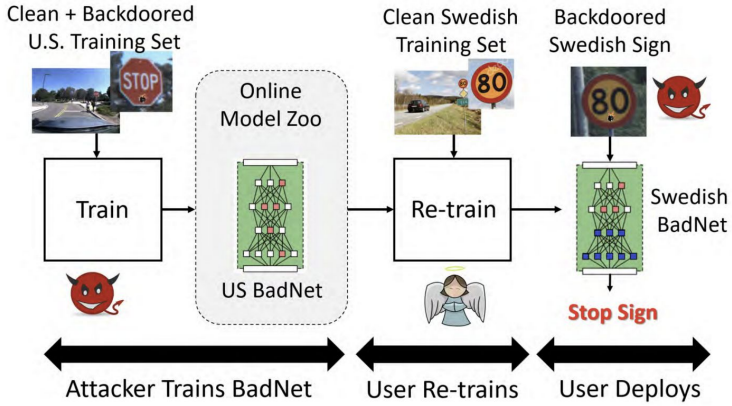

- Los **modelos preentrenados públicos pueden contener puertas traseras**.

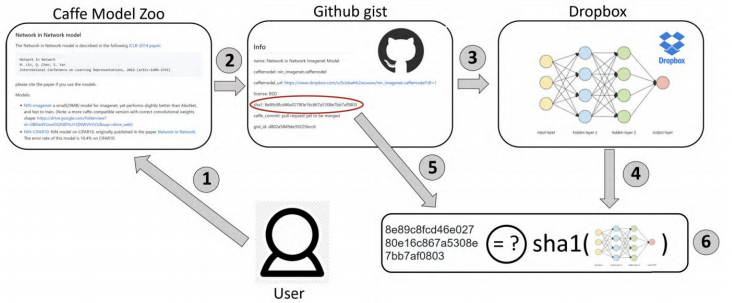

https://arxiv.org/abs/1708.06733

Ataques de envenenamiento

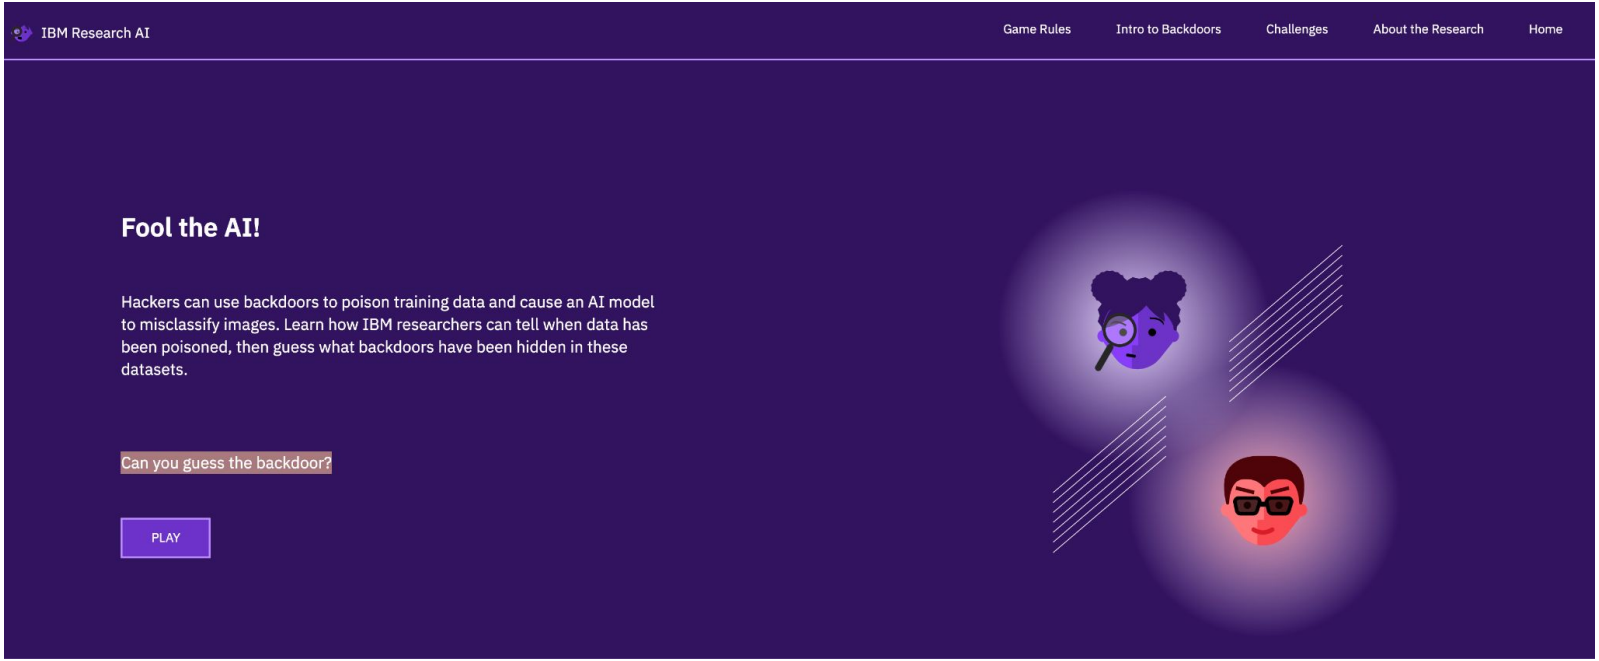

https://foolitheai.mybluemix.net

Ataques de envenenamiento
Medidas defensivas

- **Protección del dato**, que incluye evitar la **modificación, la denegación y la falsificación de los datos** y, la **detección de los datos envenenados**, junto con el uso del **saneamiento de datos**.

- **Protección de los algoritmos**, que intenta emplear **métodos robustos de entrenamiento**.

- **Defensas específicas.**

Ataques de envenenamiento

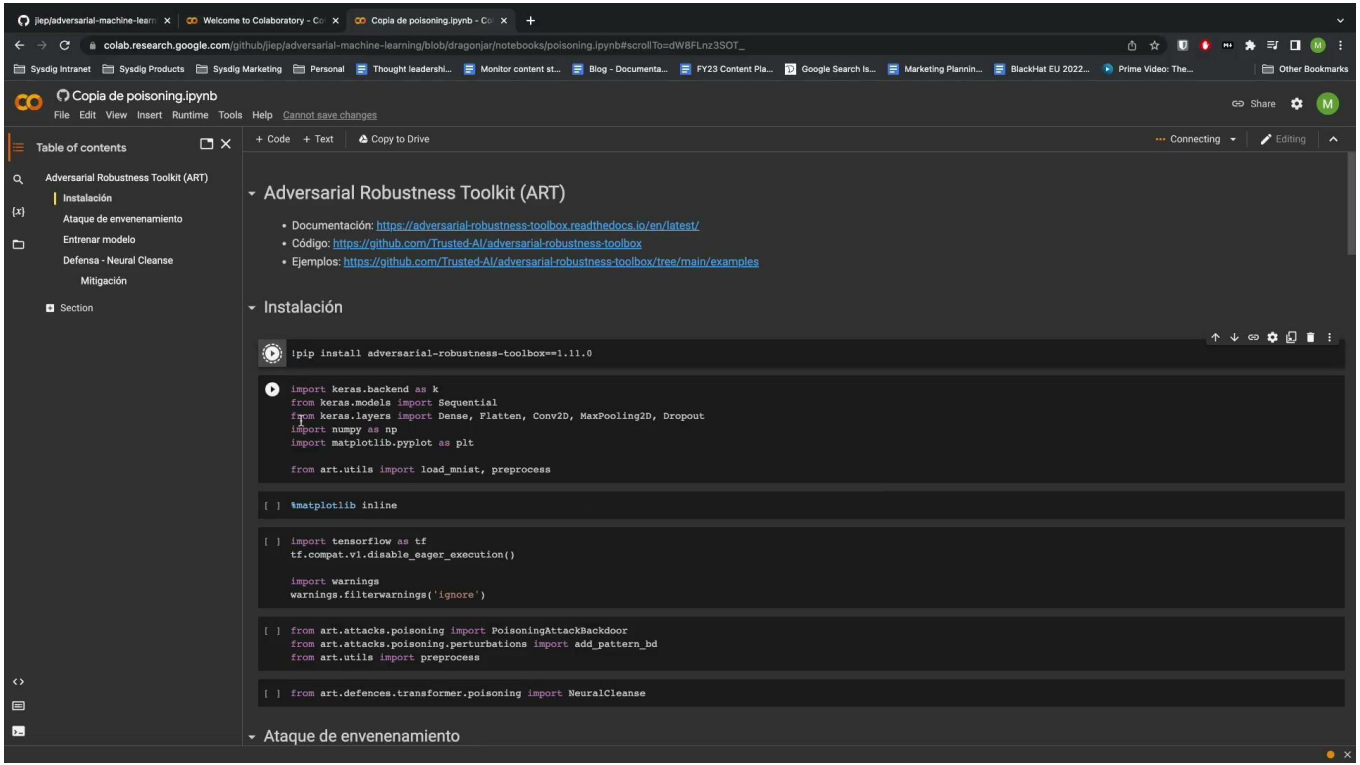

https://github.com/jiep/adversarial-machine-learning/blob/main/notebooks/poisoning.ipynb

Ataques de evasión

- Un adversario inserta una **pequeña perturbación** (en forma de ruido) en la entrada de un modelo de machine learning para que **clasifique de forma incorrecta** (ejemplo adversario).
- Son similares a los ataques de envenenamiento, pero su principal diferencia radica en que los ataques de evasión tratan de **explotar debilidades del modelo en la fase de inferencia**.
- El objetivo del adversario es que los ejemplos adversarios es que sean **imperceptibles por un humano**.

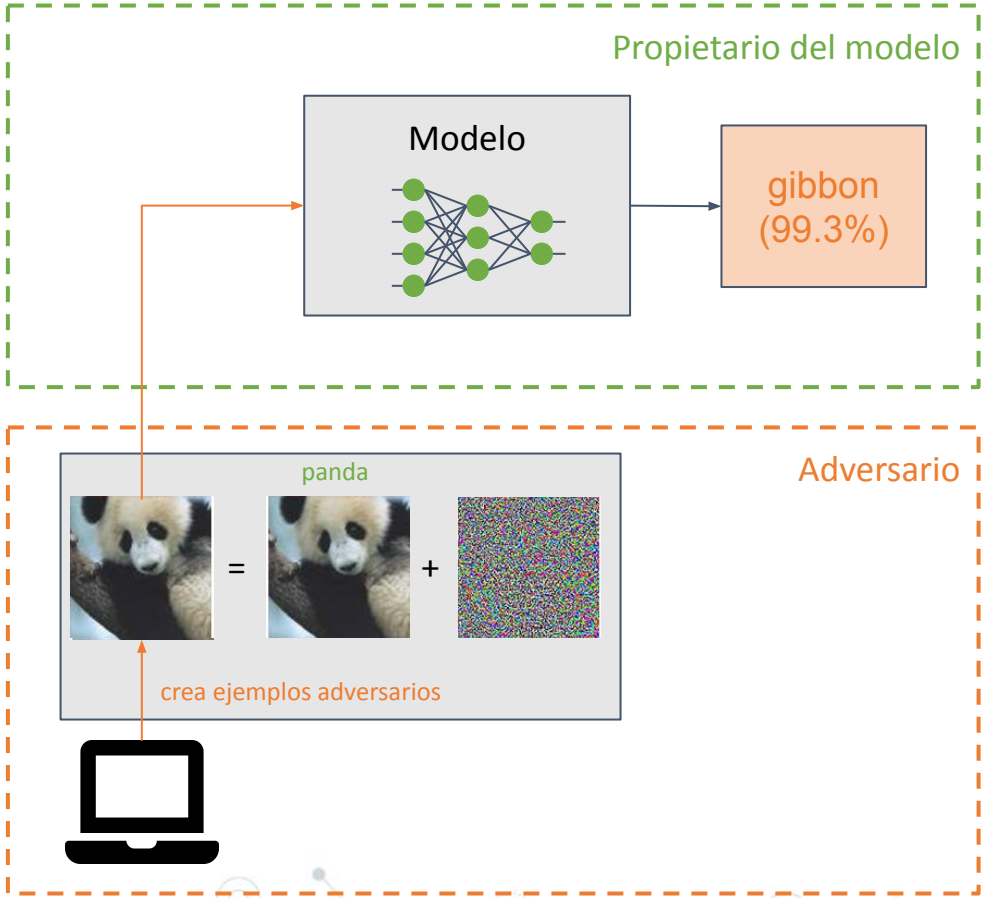

Ataques de evasión

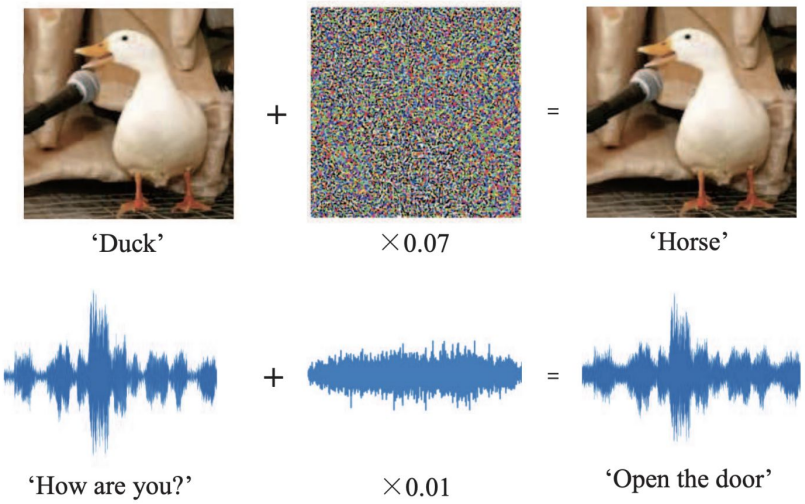

https://arxiv.org/abs/1803.09156

Classifier: Word-LSTM **Original Text Prediction**: Sci/Tech (Confidence = 47.80%) **Adversarial Text Prediction**: Business (Confidence = 52.52%)
Original Text: *Tyrannosaurus rex achieved its massive size due to an enormous growth spurt during its adolescent years.* **Adversarial Text**: *Tyrannosaurus rex achieved its massive size due to an enormous growth spurt durnig its adolescent years.*
Classifier: Text-CNN **Original Text Prediction**: Company (Confidence = 98.16%) **Adversarial Text Prediction**: Artist (Confidence = 20.27%)
Original Text: *Yates is a gardening company in New Zealand and Australia.* **Adversarial Text**: *Yates is a gardening company i New Zealand and Australia.*

https://arxiv.org/abs/2002.00760

Ataques de evasión

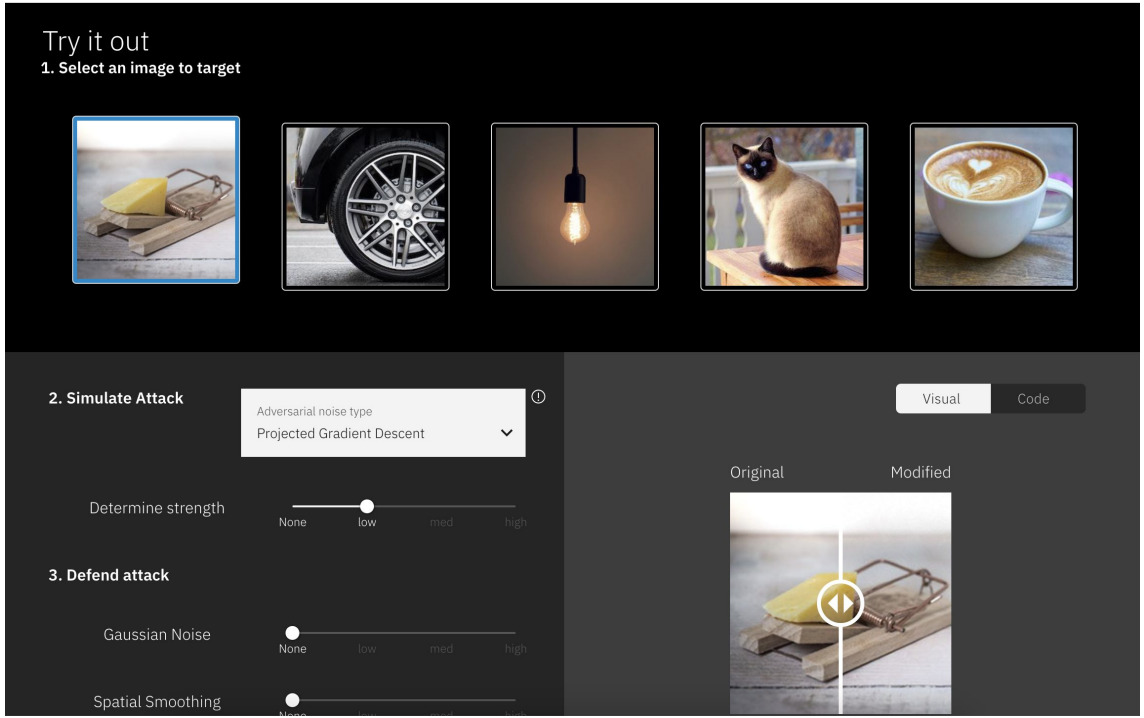

https://art-demo.mybluemix.net

Ataques de evasión

- **Dirigidos**: el adversario tiene por objetivo obtener una **predicción de su elección**.

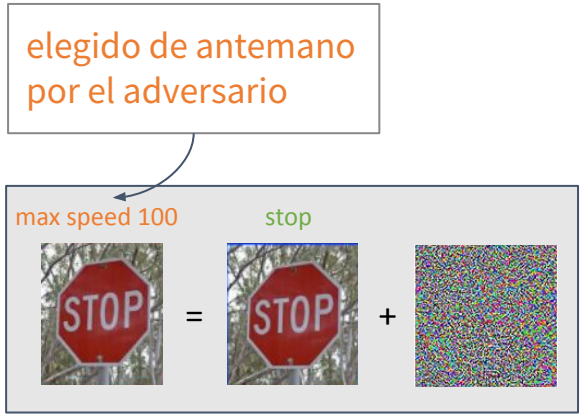

- **No dirigidos**: el adversario tiene por objetivo obtener una **clasificación de forma incorrecta**.

Ataques de evasión
Algunos ataques de caja blanca

- L-BFGS
- FGSM
- BIM
- JSMA
- Carlini & Wagner (C&W)
- NewtonFool
- EAD
- BIM
- UAP
- ...

Ataques de evasión

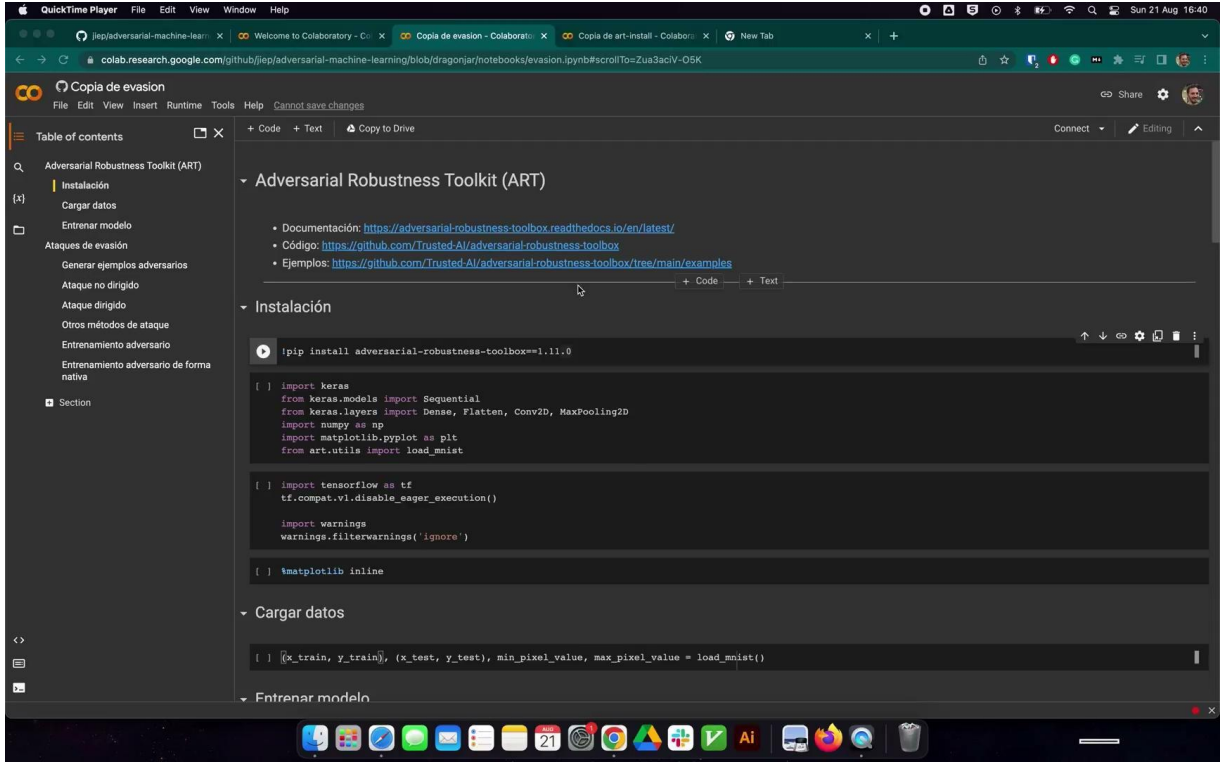

https://github.com/jiep/adversarial-machine-learning/blob/main/notebooks/evasion.ipynb

Ataques de evasión

- **Adversarial Deepfakes** (https://adversarialdeepfakes.github.io): permite la **evasión de defensas** frente a detección de **deepfakes**. En concreto, **FaceForensics++**.

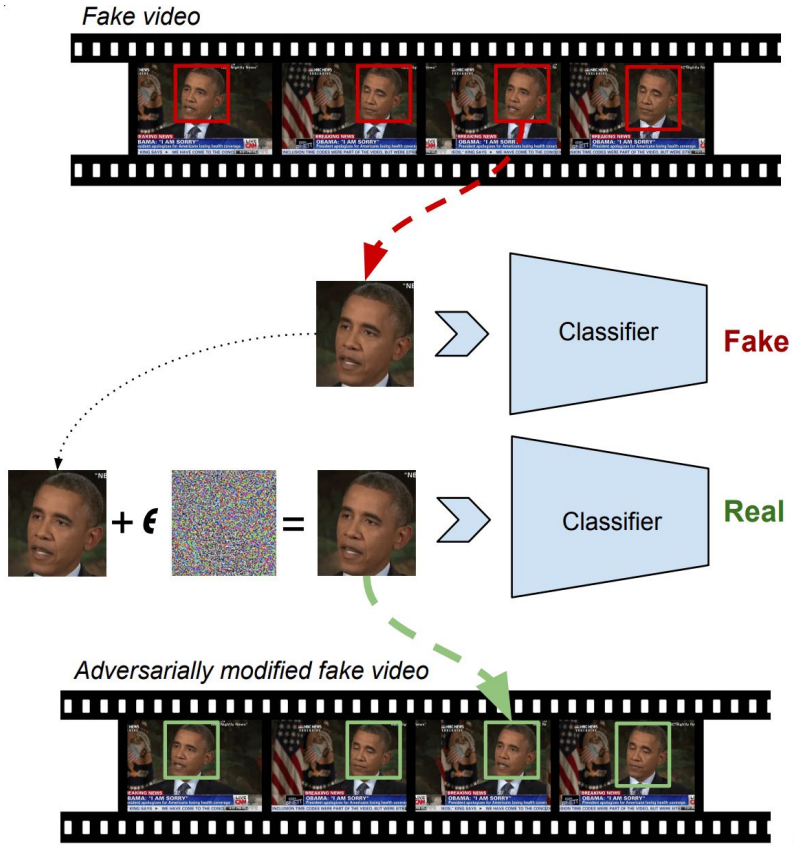

Ataques de evasión
Medidas defensivas

- **Entrenamiento adversario**, que consiste en emplear **ejemplos adversarios durante el entrenamiento** para que el modelo aprenda características de los ejemplos adversarios, **haciendo más robusto el modelo** ante este tipo de ataque.
- **Transformaciones** sobre las entradas.
- **Enmascarado/regularización del gradiente**. No muy efectiva.
- **Defensas débiles**.

Ataques de evasión

Resultado del ataque

https://github.com/jiep/adversarial-machine-learning/blob/main/notebooks/counterfit.md

4.
Conclusiones

*"If you use **machine learning**, there is the risk for exposure, even **though the threat does not currently exist in your space**."*

*"The **gap** between **machine learning and security** is definitely there."*

*"Through 2022, 30% of all AI cyberattacks will leverage **training-data poisoning**, AI **model theft**, or **adversarial samples** to attack AI-powered systems."*

Conclusiones

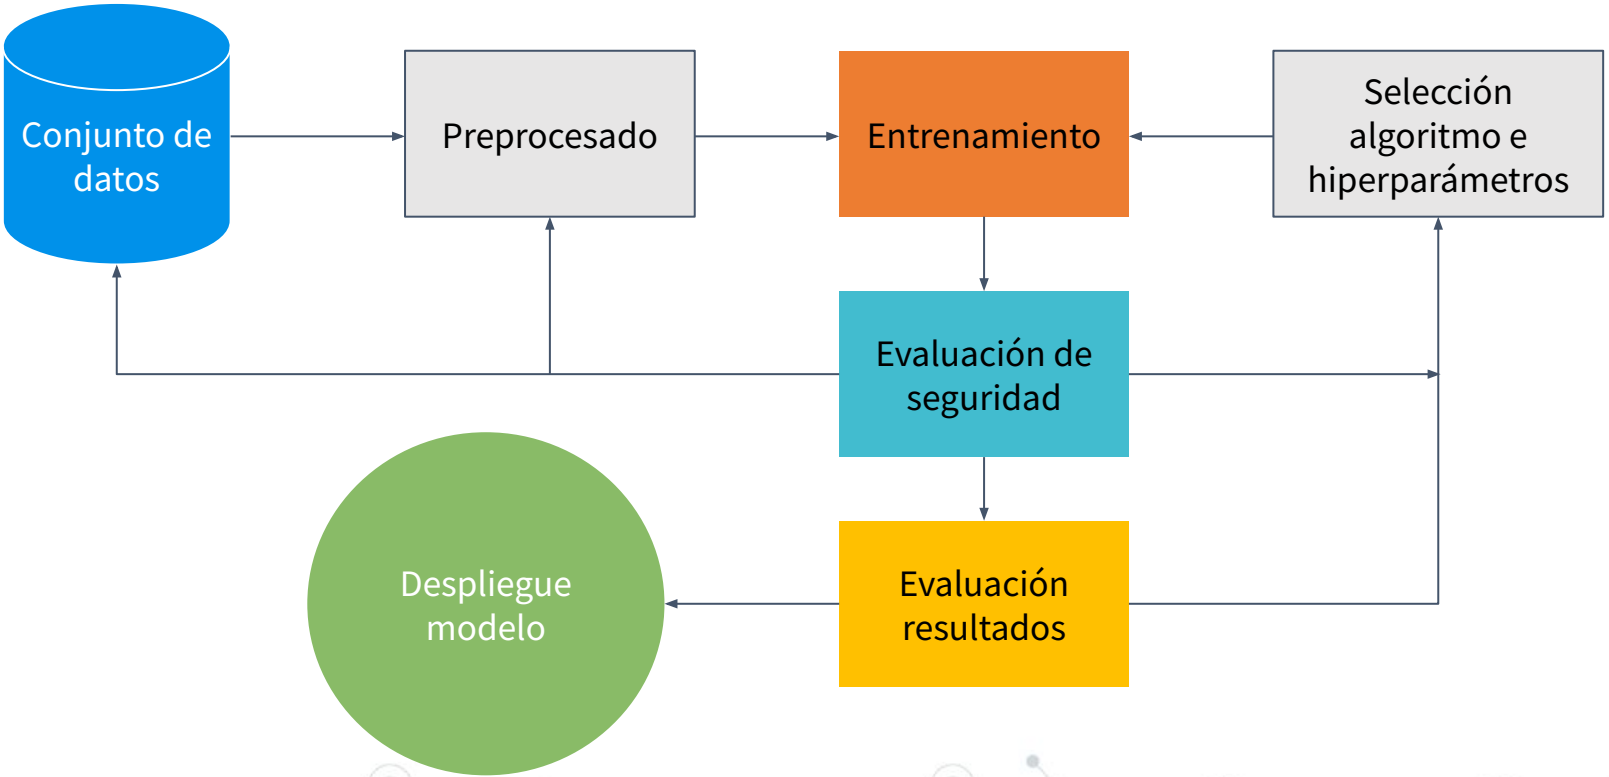

Siguientes pasos

- @dawnsongtweets
- @goodfellow_ian
- @NicolasPapernot
- @biggiobattista
- Nicholas Carlini
- David Wagner
- Anish Athalye
- Martín Abadi
- Aleksander Mądry

NEURAL INFORMATION PROCESSING SYSTEMS

DEFCON

ICML International Conference On Machine Learning

AAAI Association for the Advancement of Artificial Intelligence

acm SIGSAC ACM Conference on Computer and Communications Security

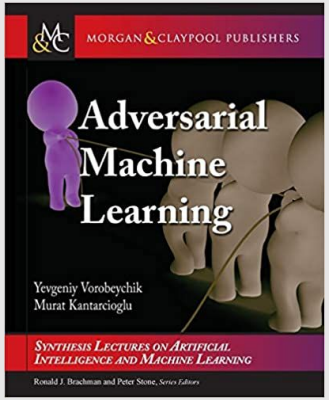

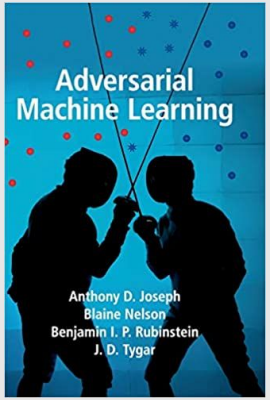

NVIDIA MINTNV

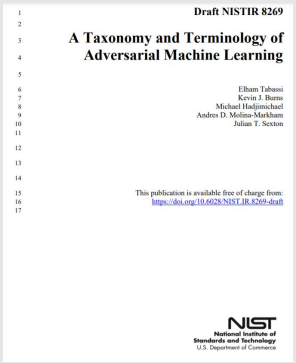
Draft NISTIR 8269

A Taxonomy and Terminology of Adversarial Machine Learning

Elham Tabassi
Kevin J. Burns
Michael Hadjimichael
Andres D. Molina-Markham
Julian T. Sexton

This publication is available free of charge from: https://doi.org/10.6028/NIST.IR.8269-draft

NIST National Institute of Standards and Technology U.S. Department of Commerce

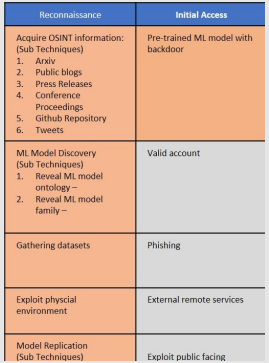

Reconnaissance	Initial Access
Acquire OSINT information: (Sub Techniques) 1. Arxiv 2. Public blogs 3. Press Releases 4. Conference Proceedings 5. Github Repository 6. Tweets	Pre-trained ML model with backdoor
ML Model Discovery (Sub Techniques) 1. Reveal ML model ontology – 2. Reveal ML model family –	Valid account
Gathering datasets	Phishing
Exploit physcial environment	External remote services
Model Replication (Sub Techniques)	Exploit public facing

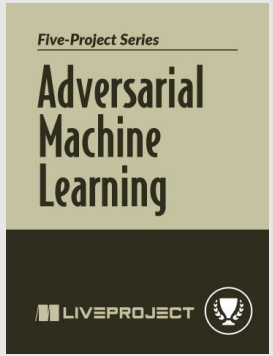

¡Gracias por su atención!

¿Alguna pregunta?

https://github.com/jiep/adversarial-machine-learning

@MiguelHzBz

/in/josé-ignacio-escribano-pablos

Después de proteger la infraestructura y los datos, deberías preocuparte por tus modelos de IA.

Introducción al Adversarial Machine Learning